

Métrica RAPM: Evaluación del impacto ofensivo y defensivo de los jugadores de la Liga Nacional de Básquetbol en Argentina

Tesina de grado

Estudiante: Simón Pedro Gazze

Director: Andrés Sosa

Co-directora: Cristina Cuesta

Fecha: 18 de febrero de 2026



1 Resumen

El crecimiento de la analítica deportiva ha impulsado el desarrollo de métricas destinadas a evaluar con mayor precisión la contribución de los jugadores al rendimiento de sus equipos. Particularmente en el básquetbol, las estadísticas individuales derivadas del box score presentan limitaciones para capturar el impacto real de los jugadores sobre el resultado del juego. Una de las medidas desarrolladas con este propósito es el *plus-minus*, que registra la diferencia de puntos generada mientras un jugador permanece en cancha. Sin embargo, esta métrica presenta dificultades para aislar el efecto propio de cada jugador respecto del contexto en el que participa. En respuesta a esta problemática surge el *Regularized Adjusted Plus Minus* (RAPM), una medida basada en modelos estadísticos que estima el impacto ofensivo y defensivo de cada jugador controlando simultáneamente la presencia de compañeros y rivales en cancha.

El objetivo de este trabajo es estimar el impacto individual de los jugadores de la Liga Nacional de Básquetbol de Argentina durante la temporada 2024/2025 mediante modelos RAPM, construyendo rankings que permitan identificar y comparar sus contribuciones ofensivas y defensivas. Asimismo, se analizan distintas alternativas metodológicas para abordar problemas recurrentes en este tipo de modelos, particularmente la multicolinealidad entre jugadores y la presencia de coeficientes extremos asociados a jugadores con escasa participación en cancha.

Las acciones de juego registradas fueron agrupadas en posesiones, que constituyen la unidad de análisis utilizada para la estimación de las métricas propuestas. Inicialmente, se ajustaron modelos de regresión lineal múltiple, incorporando distintas técnicas de regularización. Posteriormente, se implementaron modelos de regresión logística multinomial que representan de manera más adecuada la naturaleza discreta de la variable respuesta. A partir de las probabilidades estimadas por estos modelos se construyeron métricas basadas en puntos esperados por posesión (EPTS). Finalmente, se propuso una ponderación a dicha métrica denominada wEPTS, que incorpora la participación de cada jugador relativa a las posesiones de su equipo con el objetivo de penalizar a los jugadores con poco tiempo de juego. Los resultados obtenidos muestran que esta métrica presentó un desempeño superior al de las alternativas

propuestas, de acuerdo con los distintos criterios de validación utilizados.

Este estudio constituye la primera aplicación de métricas RAPM en la Liga Nacional de Básquetbol de Argentina y aporta una metodología reproducible para la evaluación objetiva del rendimiento individual de los jugadores, contribuyendo al desarrollo de herramientas de analítica deportiva en el contexto del básquetbol argentino.

Palabras clave: básquetbol, analítica en el deporte, Liga Nacional de Básquet, plus-minus, RAPM, regresión logística multinomial, regularización.

Contenido

1 Resumen

2	Introducción	1
	Sports Analytics	1
	Análítica deportiva en el básquetbol argentino	2
	Medidas de desempeño para jugadores de básquetbol	3
	<i>Regularized Adjusted Plus Minus</i> (RAPM)	4
2.1	Objetivos	7
2.1.1	Objetivo general	7
2.1.2	Objetivos específicos	7
2.2	Organización de la tesina	7
3	Datos	8
3.1	Generación de la base de datos a partir de técnicas de Web Scraping	9
3.1.1	Listado de links de los partidos	9
3.1.2	Base de datos <i>play-by-play</i>	11
3.1.3	Tabla de jugadores-equipos	12
3.2	Preprocesamiento de los datos	14
3.2.1	Integración del <i>box score</i> con el <i>play-by-play</i>	14
3.2.2	Identificación de los quintetos en cancha al momento de la acción	14
3.3	Generación de la base de datos <i>poss-by-poss</i>	16
3.3.1	Eliminación de acciones no relevantes para la posesión	17

3.3.2	Manejo de otro tipo de acciones particulares	18
3.3.3	Identificación de la finalización de las posesiones	20
3.3.4	Cálculo y validación de los puntos por posesión	21
3.3.5	Identificación de jugadores ofensivos y defensivos en cancha	23
3.4	Base de datos final: <i>poss-by-poss</i>	23
4	Metodología	24
4.1	Modelos propuestos	24
4.1.1	Modelo de regresión lineal múltiple	24
4.1.2	Modelo logístico multinomial	27
4.2	EPTS y wEPTS	29
4.2.1	<i>Expected points</i> (EPTS)	29
4.2.2	<i>Weighted expected points</i> (wEPTS)	30
4.3	Estimación de los RAPMs	32
4.3.1	Método de mínimos cuadrados	32
4.3.2	Método de máxima verosimilitud	32
4.4	Multicolinealidad	33
4.5	Tratamiento de los jugadores con poco tiempo de juego (<i>Low time players</i> - <i>LTP</i>)	34
4.6	Métodos de regularización	36
4.6.1	Regresión Ridge o Regularización L_2	37
4.6.2	Lasso o Regularización L_1	38
4.6.3	Elastic Net	39
4.7	Selección de hiperparámetros óptimos	40

4.8	Comparación de modelos	41
4.8.1	Bondad de ajuste	42
4.8.2	Evaluación de la consistencia de los resultados	44
4.8.3	Criterios de validación externa	45
5	Resultados	46
5.1	Análisis descriptivo	46
5.1.1	Puntos por posesión	47
5.1.2	Rendimiento de los equipos	47
5.1.3	Análisis de <i>plus-minus</i>	48
5.1.4	Análisis del <i>plus-minus</i> por cada 100 posesiones	50
5.1.5	Análisis del <i>plus-minus</i> estandarizado por equipo	53
5.2	Métricas basadas en modelos estadísticos	56
5.2.1	RAPM	56
5.2.2	EPTS	59
5.2.3	wEPTS	61
5.3	Comparación de modelos	65
5.3.1	Bondad de ajuste	65
5.3.2	Consistencia	66
5.3.3	Validación externa	68
6	Conclusiones	72
7	Discusión	72

8	Bibliografía	74
9	Anexo	75
9.1	Controles de consistencia y corrección de errores en la base de datos	75
9.2	Detección de errores en el marcador parcial: caso <i>QUIMSA vs BOCA</i> (019/10/2024 11:30)	76

2 Introducción

Sports Analytics

Sports Analytics o analítica en el deporte es un término que refiere a la aplicación de métodos estadísticos para describir, explicar y/o predecir fenómenos vinculados al rendimiento deportivo, tanto a nivel individual como colectivo con el objetivo de facilitar la toma de decisiones de entrenadores o *staff* técnico antes, durante y después de los partidos.

A pesar de que las primeras aplicaciones al análisis de datos al deporte se remontan a mediados del siglo XX, el impulso más significativo ocurrió a partir del año 2000, en particular en el béisbol, con la popularización del enfoque conocido como *sabermetrics*¹. Desde entonces, la práctica se extendió a otros deportes como el básquetbol, el fútbol o el tenis; dando lugar a una nueva cultura de toma de decisiones basada en evidencia. Hoy en día, los equipos profesionales, las ligas y las federaciones emplean departamentos especializados en análisis de datos para optimizar estrategias de juego, evaluar el rendimiento de jugadores, prevenir lesiones y gestionar recursos económicos de manera más eficiente.

El básquetbol es uno de los deportes que más ha incorporado el análisis estadístico en su evolución reciente. Desde las primeras métricas derivadas del *box score* (resumen estructurado de los resultados de un partido), el desarrollo de bases de datos *play-by-play* (registro de cada una de las acciones del partido) a partir de la década del 2000 hasta la incorporación más reciente de tecnologías de *player tracking* (sistema que utiliza cámaras y software de visión artificial en los estadios para registrar los movimientos de jugadores y pelotas en tiempo real). A partir de esta información, se han desarrollado distintas herramientas estadísticas para poder estudiar la eficiencia de los jugadores, la eficiencia de los lanzamientos al aro, el desempeño de los equipos, la importancia en la creación de espacios, entre otras cosas.

¹Término utilizado para referirse al análisis estadístico del béisbol, basado en la recopilación y estudio sistemático de datos con el fin de comprender y cuantificar el desempeño de los jugadores y equipos. El nombre proviene de SABR (*Society for American Baseball Research*).

Análítica deportiva en el básquetbol argentino

El creciente interés por la analítica deportiva que se ha evidenciado en los últimos años en distintos países del mundo, ha empezado a captar la atención de las entidades deportivas en Argentina. Particularmente este año la Confederación Argentina de Básquetbol (CABB) y la Asociación de Clubes (AdC) anunciaron en octubre la ampliación de su alianza con Catapult (empresa australiana de tecnología deportiva), integrando equipamiento de *wearables* (GPS) y software de videoanálisis para las 19 franquicias de la Liga Nacional, las 34 de la Liga Argentina y las selecciones nacionales en todas las ramas. Mientras que en el ámbito educativo, el Instituto CAB (creado en 2023) realizó un convenio con Sports Data Campus (España) para ofrecer, en agosto de este año, el primer curso de *Big Data aplicado al básquetbol* en Argentina, con el objetivo de que entrenadores y *staff* técnico colaboren en proyectos reales de la CABB, aportando soluciones basadas en datos sobre rendimiento, *scouting* y optimización de procesos².

Estas cuestiones previamente mencionadas dan indicio de que estamos ante un momento ideal para profundizar en el estudio y la aplicación del análisis de datos en el básquetbol. Se trata de un área que comienza a reconocerse como un componente fundamental tanto para mejorar el rendimiento deportivo de los equipos como para impulsar el desarrollo del negocio en torno al deporte. Sin embargo, el potencial de la analítica aplicada al básquetbol en Argentina aún pareciera encontrarse lejos de estar plenamente aprovechado.

En este marco, y con el fin de caracterizar el estado de situación del análisis de datos en el básquet argentino, se relevaron los proyectos e iniciativas actualmente activos en el país vinculados a la estadística y la tecnología aplicada al deporte.

- *CHAS All Stats*, dirigido por Facundo Salas y Sebastián Fiol, ambos entrenadores de básquetbol Nivel 3 Eneba, especialistas en estadísticas avanzadas y analistas de datos en equipos profesionales. Ofrecen servicios de análisis táctico y brindan cursos de estadísticas avanzadas.

²Confederación Argentina de Básquetbol (2025). *La Confederación Argentina de Básquet y Sports Data Campus firman un acuerdo de colaboración*. Link al artículo.

- *Básquet Advance*, dirigido por el entrenador Cristian Sánchez, ofrece informes pre/post partido con estadísticas avanzadas y tendencias clave para entrenadores y scouts.

Ambos proyectos ofrecen herramientas muy importantes y de gran valor tanto para los equipos como para el desarrollo del análisis de datos en el deporte. Pero particularmente en ambos casos, los que llevan adelante estos proyectos son entrenadores de básquetbol, los cuales a pesar de que pueden contar con una sólida formación técnica, no son profesionales de ciencias estadística o matemática.

Por este motivo, resulta fundamental la incorporación de profesionales en carreras de ciencias exactas, que trabajen en conjunto con los entrenadores y cuerpos técnicos, para de esta manera poder ofrecer nuevos análisis más rigurosos y profundos, así como mejorar las herramientas actualmente disponibles. Esta correspondencia entre el conocimiento técnico-deportivo y el enfoque estadístico permitiría potenciar el desarrollo del básquet argentino y contribuir a elevar su nivel competitivo en un futuro.

Medidas de desempeño para jugadores de básquetbol

Desde la consolidación del *box-score* en el básquetbol profesional, durante la década de 1950, empezaron a calcularse las primeras medidas de desempeño para los jugadores, como pueden ser los puntos, rebotes, asistencias, etc. Durante mucho tiempo estas métricas constituyeron una de las formas más tradicionales de evaluar el rendimiento individual en el básquetbol. Su amplia disponibilidad y fácil interpretación las convirtieron en el principal insumo para comparar jugadores, otorgar premios o negociar contratos. Estas medidas suelen agruparse en un conjunto de estadísticas denominadas *bottom-up*, las cuales se calculan en función de las acciones individuales de los jugadores, es decir, si un jugador realiza una acción que se asocia con un resultado positivo para el equipo, la calificación de ese jugador aumenta, mientras que la calificación de los demás jugadores, que no participaron en la jugada, permanece sin cambios. Pero estas medidas presentan algunas limitaciones importantes, ya que, sólo capturan una parte de los eventos relevantes del partido (acciones como una defensa asfixiante, buenas rotaciones

defensivas o pases rápidos para iniciar una posesión no están contempladas) y no necesariamente reflejan el impacto real de un jugador en las victorias de su equipo, que es lo que importa a fin de cuentas.

Por otra parte, las medidas *top-down* se basan en el rendimiento del equipo en su conjunto, y el crédito por dicho rendimiento se distribuye entre los jugadores que estuvieron involucrados en el partido, sin importar qué acciones puntuales hayan realizado.

Con la idea de que lo más importante en un partido es ganar, y entendiendo que las estadísticas tradicionales son solo una medida imperfecta de muchas de las contribuciones que realizan los jugadores a la victoria, en este trabajo buscaremos “pensar más allá del *box score*” y nos centraremos en estadísticas *top-down*, más precisamente en la medida *plus-minus*. Esta estadística registra los cambios que se producen en el marcador durante los minutos en que el jugador de interés está en cancha, partiendo de la idea de que los equipos deberían rendir mejor (reflejado en un *plus-minus* más alto) cuando sus buenos jugadores están en cancha que cuando no lo están. Sin embargo esta métrica posee una deficiencia clave: **la calificación de cada jugador va a depender en gran medida de la calidad de sus compañeros en el campo**. Por ejemplo: un jugador de rol dentro de un gran equipo va a tener un mayor *plus-minus* que una superestrella en un equipo con mal desempeño.

Regularized Adjusted Plus Minus (RAPM)

La deficiencia anteriormente mencionada se ha intentado solucionar implementando modelos matemáticos que incorporen los efectos tanto de los compañeros presentes en cancha como de los rivales en ese momento, buscando aislar el efecto real de los jugadores en la cancha. El primero en realizar una publicación sobre el tema fue Dan Rosenbaum (2004), el cual planteó un modelo de regresión lineal múltiple en base a observaciones provenientes de partidos de las temporadas 2002-2003 y 2003-2004 de la *National Basketball Association* (NBA). Como unidad de análisis se utilizaron segmentos de partidos donde no ocurrieran sustituciones, la variable respuesta fue la diferencia en el marcador entre el equipo local y el visitante en ese

segmento; y como variables explicativas se postularon variables dicotómicas para cada uno de los jugadores que hayan jugado al menos un partido en esas temporadas. Finalmente las métricas de desempeño se correspondían con los coeficientes estimados que acompañaban a las “Dummies” de cada jugador, dichas estimaciones se realizaron mediante la técnica de Mínimos Cuadrados Ordinarios. Estas estadísticas se conocen como *Adjusted Plus Minus* (APM).

A pesar de que estas métricas presentaban una solución innovadora a la problemática inicial, Rosenbaum señaló que las estimaciones obtenidas no resultaron muy precisas. El modelo propuesto presentaba estimaciones con mucho error, debido a un claro problema de multicolinealidad ya que muchos de los jugadores compartían una gran cantidad de minutos juntos en cancha, y se necesitaba de una gran cantidad de observaciones de varias temporadas para que el modelo pudiera separar el efecto propio de cada jugador.

Para solucionar esta problemática, se plantea la métrica RAPM introducida por Sill (2010) en la cual se aborda el problema de la multicolinealidad mediante estimaciones de los parámetros realizadas con métodos de regularización, particularmente utilizando la Regresión Ridge. Este método de regularización es el más abordado a lo largo de toda la literatura relevante sobre RAPM hasta la fecha.

Otro de los problemas recurrentes en estos modelos está relacionado con la inclusión de jugadores que participan muy pocos minutos en cancha (*LTPs - Low time Players*). Cuando un jugador juega muy poco, el modelo solo tiene unas pocas observaciones (segmentos) para evaluarlo, y si particularmente en esas observaciones el equipo tiene un muy buen desempeño (probablemente por casualidad); entonces el modelo no puede diferenciar si el efecto es propio del jugador y estima coeficientes extremos. Para solucionar estos casos se han contemplado las siguientes alternativas: 1) excluir a los jugadores con pocos minutos dentro de las temporadas (por ejemplo: Rosembaum (2004) excluye a los jugadores con menos de 250 minutos, Ilardi (2007) excluyen a los jugadores con menos de 400 minutos, etc), 2) utilizar una gran cantidad de observaciones (Ilardi & Barzilai (2008) incorpora información de 5 temporadas), 3) plantear métodos de estimación de los parámetros que penalicen a este tipo de jugadores.

En los últimos años, muchos investigadores han publicado trabajos orientados a mejorar los resultados de las métricas RAPM. Particularmente en este trabajo se usa como referencia central al artículo titulado **Lasso multinomial performance indicators for in-play basketball data** (Damoulaki et al. , 2025), el cual presenta diferencias importantes respecto de los estudios previos. Dicho artículo utiliza posesiones (definidas, según Kubatko et al. (2007), como el periodo que comienza cuando un equipo obtiene el control de la pelota y termina cuando cede su control al rival) como unidad de análisis, puntos en esas posesiones como variable respuesta y emplea modelos logísticos multinomiales que representan de manera más adecuada la naturaleza de la respuesta.

2.1 Objetivos

2.1.1 Objetivo general

El objetivo general de esta tesina es estimar el aporte individual de los jugadores de la Liga Nacional de Básquetbol de Argentina durante la temporada 2024/2025 mediante modelos RAPM, con el fin de construir un ranking que refleje su impacto en el desempeño de sus equipos.

2.1.2 Objetivos específicos

- 1) Generar una base de datos del tipo *play-by-play* para la temporada 2024/2025 de la Liga Nacional de Básquetbol de Argentina, mediante técnicas de *web scraping*.
- 2) Diferenciar el aporte ofensivo y defensivo de cada uno de los jugadores de la liga, obteniendo finalmente rankings que identifiquen a los mejores jugadores en cada rubro.
- 3) Desarrollar una metodología adecuada que permita solucionar el problema de los coeficientes extremos asociados a los jugadores con pocos minutos de juego (*LTPs Players*) durante la temporada.
- 4) Comparar modelos en base a distintos criterios de evaluación, para poder determinar cual de ellos proporciona mejores métricas, debiendo resumir de manera consistente y precisa el aporte ofensivo y defensivo de cada jugador en relación al desempeño de su equipo.

2.2 Organización de la tesina

El trabajo se organiza de la siguiente manera:

En el Capítulo 2 se describe el proceso de generación y procesamiento de los datos. Se detalla la construcción de la base *play-by-play* mediante técnicas de *web scraping*, las etapas de limpieza

y preprocesamiento de la información y la generación de la base *poss-by-poss* utilizada para el ajuste de los modelos estadísticos.

En el Capítulo 3 se desarrolla la metodología estadística empleada en el trabajo. Se presentan los modelos propuestos, las métricas derivadas de los mismos, los principales problemas que suelen presentarse en este tipo de enfoques y las técnicas de regularización utilizadas para abordarlos. Finalmente, se describen los criterios adoptados para comparar el desempeño de los distintos modelos considerados.

En el Capítulo 4 se presentan los resultados obtenidos. Inicialmente, se realiza un análisis descriptivo de los datos y de distintas medidas basadas en plus-minus. Posteriormente, se analizan los rankings obtenidos mediante RAPM, EPTS y wEPTS y se comparan las distintas alternativas propuestas de acuerdo con los criterios de evaluación definidos previamente.

En el Capítulo 5 se presentan las principales conclusiones del trabajo, sintetizando los resultados más relevantes obtenidos a partir de la comparación de los distintos modelos.

Finalmente, en el Capítulo 6 se discuten los alcances y limitaciones del enfoque adoptado, y se plantean posibles líneas de investigación futura.

3 Datos

Una parte central de esta tesina estará dedicada a la construcción de una base de datos *play-by-play* correspondiente a la temporada 2024/2025 de la Liga Nacional de Básquetbol de Argentina (LNB). Este tipo de base registra de manera secuencial todas las acciones ocurridas dentro de un partido. Dado que no existe una fuente oficial que provea los datos en formato estructurado y descargable para su análisis estadístico, fue necesario diseñar y ejecutar un proceso de *web scraping* que permita recolectar, integrar y depurar la información de manera sistemática y reproducible. Los datos necesarios se extrajeron del Sitio Oficial de la Liga Nacional de Básquet, utilizando librerías de Python como `Selenium` y `BeautifulSoup`.

Posteriormente, se realizó un preprocesamiento orientado a transformar los eventos crudos en

un *dataset* apto para cumplir los objetivos específicos de este trabajo. Como resultado, se obtuvo una base de datos ordenada cronológicamente en la cual cada fila corresponde a una posesión del partido, contabilizando los puntos anotados durante esa posesión y los jugadores que formaron parte de la misma, diferenciando sus roles ofensivos y defensivos. Debido a que bajo esta metodología se registran cada una de las posesiones del partido de manera secuencial, se denominó a esta estructura final como: base de datos *poss-by-poss*.

3.1 Generación de la base de datos a partir de técnicas de Web Scraping

3.1.1 Listado de links de los partidos

El primer paso consistió en la identificación y recopilación de los enlaces a las páginas webs que contienen las estadísticas individuales de todos los partidos incluidos en el período de estudio (378 partidos de temporada regular). Para ello, se accedió a la página de la Liga Nacional, sección Fixture, la cual presenta una tabla dinámica con los encuentros disputados y permite acceder a la información detallada de cada partido.

EQUIPOS

NOTICIAS

FORMATO

FIXTURE

ESTADÍSTICAS

GALERÍA

Desde

01/01/2025

Hasta

01/02/2026

Local	Visitante		Fecha/Hora - Campo	Estadísticas
BOCA	82	67	RACING (CH) 24/09/2025 21:30 LUIS CONDE	
PLATENSE	82	87	FERRO 25/09/2025 20:30 CIUDAD DE VICENTE LOPEZ	
LA UNION FSA.	85	91	REGATAS (C) 25/09/2025 21:00 CINCUENTENARIO	
QUIMSA	72	73	INSTITUTO 25/09/2025 21:30 CIUDAD	
SAN LORENZO	82	74	PEÑAROL (MDP) 26/09/2025 20:30 ROBERTO PANDO	
SAN MARTÍN (C)	76	49	ATENAS (C) 26/09/2025 21:00 RAUL ARGENTO ORTIZ	

Figura 1: Fixture dentro de la página web de la LNB.

En la Figura 1 se muestra la interfaz del sitio web, donde se visualiza el listado completo de partidos de la temporada para el rango de fechas seleccionadas. Dado que no pudo automatizarse

la obtención de cada uno de estos links, se procedió a copiar manualmente el *DOM* (*Document Object Model*) de la página y a pegarlo en un archivo de texto.




Figura 2: Inspección de la página web.

A partir de dicho archivo de texto, se utiliza la librería BeautifulSoup de Python para recorrer la estructura del DOM, identificando previamente los elementos que contienen los enlaces de cada partido. En la Figura 2 se observa que esta información se encuentra dentro de las clases “fila-tabla-calendarios-datos-estadisticos”, las cuales se recorren para obtener los respectivos enlaces a las páginas de estadísticas de cada partido, los nombres de los equipos participantes, la fecha y hora del encuentro y el resultado final, para cada uno de los 378 partidos disputados en la temporada regular. Obteniendo finalmente un diccionario que contenga toda esta información.

Dicho diccionario constituyó el insumo básico para el proceso posterior de scraping masivo, sobre los cuales se iterará para obtener así la información correspondiente a cada una de las acciones registradas en cada partido. Esta estrategia permitió, además, asegurar la reproducibilidad del proceso, ya que el listado de partidos es eliminado de la página web una vez terminada la temporada, quedando fijado y documentado de manera explícita para su uso, en caso de ser requerido.

3.1.2 Base de datos *play-by-play*

Una vez obtenido el listado completo de enlaces correspondientes a cada uno de los partidos en el período de estudio, se procedió a la extracción del registro de acciones del partido (*play-by-play*). Para esto, se accedió individualmente a la página de estadísticas de cada encuentro, particularmente a la pestaña denominada “En vivo”, donde se presenta el detalle secuencial de los eventos.

La Figura 3 muestra esta pestaña del sitio web, la cual contiene una tabla que se genera dinámicamente donde se registran, en orden cronológico, todas las acciones ocurridas durante el partido.




Figura 3: Pestaña en vivo dentro de la página web de estadísticas de un partido

En dicha tabla, cada acción del partido se encuentra representada como un elemento que incluye información textual sobre el tipo de acción (por ejemplo, lanzamiento convertido, falta, pérdida,

etc), el jugador que realiza dicha acción, el cuarto de juego, el tiempo restante en el cuarto y, en caso de ser una acción donde se generan puntos, el marcador parcial en ese momento del partido. Esta información fue sistemáticamente extraída y almacenada en una estructura tabular, conservando el orden temporal de las acciones.

Este procedimiento se aplicó de forma idéntica a todos los partidos de la temporada analizada, utilizando como insumo los enlaces previamente identificados. Finalmente, los registros de acciones obtenidos para cada encuentro fueron concatenados en una única base de datos *play-by-play*. Para conservar la correspondencia entre cada acción y su partido de origen, se incorporó un identificador construido a partir de los nombres de los equipos participantes y la fecha y hora del encuentro. También se añadieron las variables correspondientes al equipo local y visitante, obtenidas previamente a partir del fixture.

Es importante destacar que el *dataset* resultante constituye una secuencia detallada de eventos, pero en su forma original no incluye una identificación explícita del equipo asociado a cada acción, lo cual resulta indispensable a la hora de realizar los análisis posteriores.

3.1.3 Tabla de jugadores-equipos

Para resolver este problema, se obtuvo dicha información a partir de los datos provenientes del *Box Score*, localizados en la pestaña “Estadísticas” de la página web del partido (Figura 4). Aquí encontraremos información referida a cada uno de los jugadores anotados en la planilla de ambos equipos.

Figura 4: Ejemplo del Box Score de un partido

En esta pestaña, la información se organiza en dos tablas con estadísticas individuales de los jugadores, una correspondiente al equipo local y otra al equipo visitante, las cuales aparecen en el mismo orden en que se muestran los nombres de los equipos en la interfaz del sitio web. A partir de esta estructura, se extrajo para cada jugador su nombre completo, el equipo al que pertenece y la cantidad de minutos disputados en dicho partido, generándose así una tabla de correspondencia jugador–equipo.

Esta tabla constituye un diccionario que permite asociar a cada jugador con su respectivo equipo y es utilizada posteriormente como insumo para realizar dicha correspondencia en cada acción de la base *play-by-play*.

3.2 Preprocesamiento de los datos

3.2.1 Integración del *box score* con el *play-by-play*

Una vez construida la tabla jugadores-equipos, se procedió a integrar dicha información con la base de datos *play-by-play*. Para ello, los nombres de los jugadores fueron previamente normalizados con el objetivo de reducir posibles inconsistencias de formato (espacios adicionales, diferencias menores de escritura), y luego se utilizó la correspondencia jugador–equipo para asignar a cada acción del *play-by-play* el equipo del jugador involucrado.

De este modo, cada acción queda asociada explícitamente a uno de los dos equipos del partido, aun cuando dicha información no se encuentre disponible de forma directa en el registro original del *play-by-play*. Este procedimiento permite identificar qué jugadores estarán en cancha para cada uno de los equipos, permitiendo construir los quintetos en cada momento del partido.

3.2.2 Identificación de los quintetos en cancha al momento de la acción

A partir de la nueva tabla generada, se procedió a construir la presencia de los jugadores en cancha a lo largo del partido. Para ello, se identificaron las acciones asociadas a sustituciones, distinguiendo entre entradas (acción = ENTRA A PISTA) y salidas de jugadores (acción = ABANDONA LA PISTA), tal como se observa en la Figura 5.




Figura 5: Ejemplo de secuencia de acciones con sustitución

El conjunto de jugadores en cancha se actualiza a medida que se recorren las acciones del partido, reiniciándose al comienzo de cada cuarto. De este modo, para cada instante del juego se obtiene el conjunto de jugadores activos en cancha.

Utilizando la tabla jugadores-equipos construida previamente, cada jugador en cancha fue asignado al equipo local o visitante, permitiendo reconstruir los quintetos de ambos equipos en cada acción del partido. Este paso resulta esencial para caracterizar el contexto en el que ocurre cada acción, ya que, al conocer el equipo al que pertenece el jugador que realiza la acción podemos inferir simultáneamente los jugadores ofensivos y defensivos presentes en cancha en cada momento.

Una vez reconstruidos los quintetos en cancha para cada acción, se incorporó un control de consistencia basado en la cantidad total de jugadores activos. Dado que una situación de juego regular involucra diez jugadores (cinco por equipo), se podrán identificar aquellas acciones en las que la cantidad total de jugadores en cancha fuera superior o inferior a dicho umbral.

Una vez reconstruidos los quintetos en cancha para cada acción, se realizaron controles de consistencia sobre su conformación, verificando que la cantidad de jugadores registrados para cada equipo fuera compatible con una situación regular de juego. Estos controles resultan especialmente relevantes debido a que la información del *play-by-play* es cargada manualmente por las mesas de control durante el desarrollo altamente dinámico de un partido los partidos, por lo que pueden presentarse errores en la registración de eventos. El detalle de los controles realizados y de las inconsistencias detectadas y corregidas se presenta en el Anexo.

3.3 Generación de la base de datos *poss-by-poss*

Como resultado del trabajo realizado en la Sección 5.1 y 5.2, se pudo obtener una base de datos unificada donde cada fila se corresponde con cada una de las jugadas o acciones que suceden dentro del partido, incluyendo información relevante para este trabajo como lo es el marcador del partido al momento de la acción, la composición de los quintetos en cancha y la condición de local o visitante de los equipos. Sin embargo, para poder aplicar los modelos

estadísticos mencionados, resulta necesario agrupar estas acciones en **posesiones**, entendidas como el conjunto de acciones ocurridas antes de que cambie el control de la pelota.

Para llevar a cabo este proceso fue necesario definir una metodología adecuada que permita diferenciar qué acciones pertenecían a una misma posesión, y en qué momento comenzaba una distinta.

3.3.1 Eliminación de acciones no relevantes para la posesión

Este procedimiento no pudo realizarse de manera directa, ya que, a pesar de contar con información secuencial sobre el equipo responsable de cada acción, no todo cambio en el equipo asociado a una acción implica necesariamente un cambio de posesión del balón. Existen situaciones en las que se registran acciones del equipo defensor dentro de una posesión del equipo atacante. A los cuales se ha decidido por llamar como “acciones intrusas”. Un ejemplo de la contabilización correcta e incorrecta de las posesiones a partir de la secuencia de acciones se presenta en la Figura 6.



Figura 6: Comparación entre distintas formas de contabilizar las posesiones

Luego de hacer una revisión manual en un conjunto limitado de partidos, se llegó a la definición de que el conjunto de acciones presentes en el Cuadro 1 suelen ser siempre acciones intrusas o nunca resultan informativas para la delimitación de las posesiones. En consecuencia se ha decidido eliminar las filas en las que ocurren estas acciones en la base de datos. Estas acciones son:

Cuadro 1: Acciones eliminadas por no ser informativas para la delimitación de las posesiones

N°	Acción
1	ENTRA A PISTA
2	INICIO DEL PERIODO
3	FINAL DEL PERIODO
4	ABANDONA LA PISTA
5	TAPON REALIZADO
6	TECNICA
7	TECNICA BANQUILLO (C)
8	TECNICA BANQUILLO (B)
9	TECNICA DESCALIFICANTE
10	TECNICA DESCALIFICANTE ACOMPAÑANTE NO PARTICIPA
11	TECNICA-E (ALINEACIÓN ILEGAL)
12	TIEMPO MUERTO SOLICITADO
13	ANTIDEPORTIVA

3.3.2 Manejo de otro tipo de acciones particulares

1) Tratamiento de la flecha de alternancia

En el básquetbol bajo reglamento FIBA, la flecha de alternancia determina la posesión del balón en los inicios de cuarto o en situaciones de salto entre dos. Cuando este evento aparece registrado en el *play-by-play*, el equipo que obtiene la posesión es el opuesto al que figura inicialmente asociado a la acción.

Para corregir este comportamiento, se implementó una regla que invierte el equipo asignado a la acción en presencia de una flecha de alternancia, garantizando la correcta identificación del equipo en control del balón.

2) Eliminación de rebotes defensivos al final de cada cuarto

Se detectó que, en algunos casos, el *play-by-play* registra un rebote defensivo como última acción de un cuarto. Ya que esta situación sucede quedando unos pocos segundos para terminar el cuarto, no debe ser contabilizada como una posesión real, y para evitar dichas situaciones se eliminaron dichas acciones de la base de datos.

3) Reglas específicas para el tratamiento de faltas ofensivas

Las faltas ofensivas representan un caso particular dentro del *play-by-play*, ya que no son diferenciadas de las faltas defensivas en la descripción de la acción, y tienen una diferencia fundamental a la hora de definir las posesiones. Por un lado, las faltas defensivas corresponden a una “acción intrusa” y deben ser eliminadas de la base, mientras que las faltas ofensivas siempre implican un cambio inmediato de posesión y, en ocasiones, pueden ser la única acción que realice un equipo dentro de una posesión, como se observa en la Figura 7. Por lo que en esos casos puntuales dicha acción debe conservarse.

En consecuencia, se desarrolló un conjunto de reglas basadas en el contexto de la acción previa para decidir si una falta debe ser conservada o eliminada del registro. Particularmente, se definió que: una falta debe conservarse si el equipo que la comete es distinto al equipo que realizó la acción inmediata anterior, siempre que dicha acción previa sea

- 1) un lanzamiento fallido,
- 2) una pérdida de balón,
- 3) una anotación con una separación temporal suficiente³ que indique el transcurso de una nueva posesión.

Todas las faltas que no cumplieran esta condición fueron eliminadas para evitar errores en el conteo de posesiones.

³Si a una anotación le sigue una falta inmediata del rival, resulta ser la denominada “falta y conversión” la cual forma parte de la misma posesión.




Figura 7: Ejemplo de falta ofensiva en una secuencia de acciones

3.3.3 Identificación de la finalización de las posesiones

Una vez realizadas estas tareas de preprocesamiento, se incorporó un identificador preliminar de posesión, basado en dos criterios fundamentales: el cambio de equipo en control del balón y el cambio de cuarto. De manera que cada vez que ocurre alguno de estos eventos, se identifica como el inicio de una nueva posesión. Esto se encuentra ejemplificado en el Cuadro 2.

Cuadro 2: Ejemplo de secuencia de acciones diferenciando cada posesión

Cuarto	Tiempo	Acción	Jugador	Equipo	...	Posesión
1	00:08:54	TIRO DE 3 FALLADO	STENTA, NICOLAS	BOCA		4
1	00:09:12	REBOTE DEFENSIVO #11	VILDOZA, JOSE IGNACIO	BOCA		4
1	00:09:13	TIRO DE 3 FALLADO	BUEMO, CARLOS EMANUEL	ATENAS		3
1	00:09:18	FALTA RECIBIDA	BUENDIA, CARLOS MANUEL	ATENAS		3
1	00:09:32	TRIPLE	PIÑERO, FACUNDO	BOCA		2
1	00:09:42	REBOTE DEFENSIVO #11	VILDOZA, JOSE IGNACIO	BOCA		2
1	00:09:43	TIRO DE 2 FALLADO	OBERTO, JUAN CRUZ MATEO	ATENAS		1

Una vez identificadas las posesiones, se conservó para cada una de ellas la última acción registrada, correspondiente al cierre de la posesión, y se descartaron las acciones intermedias. De esta forma, la base pasó de contener una fila por acción a contener una fila por posesión.

3.3.4 Cálculo y validación de los puntos por posesión

En primera instancia, para obtener la cantidad de puntos generados en cada posesión, se calculó la diferencia entre el puntaje acumulado del equipo atacante al final de la posesión y el puntaje acumulado registrado al cierre de la posesión inmediatamente anterior. De esta manera, cada posesión queda caracterizada por una variable discreta que representa su resultado ofensivo en términos de puntos anotados. El Cuadro 3 muestra el resultado de este procedimiento para las mismas posesiones presentadas previamente en el Cuadro 2, ahora reducidas a una fila por posesión e incorporando la cantidad de puntos anotados.

Cuadro 3: Ejemplo de estructura con una fila por posesión

Cuarto	Tiempo	Acción	Jugador	Equipo	...	Posesión	Puntos
1	00:08:54	TIRO DE 3 FALLADO	STENTA, NICOLAS	BOCA		4	0
1	00:09:13	TIRO DE 3 FALLADO	BUEMO, CARLOS EMANUEL	ATENAS		3	0
1	00:09:32	TRIPLE	PIÑERO, FACUNDO	BOCA		2	3
1	00:09:43	TIRO DE 2 FALLADO	OBERTO, JUAN CRUZ MATEO	ATENAS		1	0

Sin embargo, durante el análisis descriptivo de esta variable, se detectaron valores incompatibles con la lógica del juego, observándose posesiones con puntos por posesión “negativos” como -4 y -2 puntos, así como también posesiones con resultados muy elevados (6,7 y 8 puntos). Estos últimos, a pesar de ser factibles, son muy poco comunes. Por este motivo se realizó una revisión manual de los partidos involucrados con el objetivo de identificar el origen del problema.

La inspección de los registros permitió comprobar que, en cinco partidos, el marcador acumulado informado en el código HTML presentaba errores de actualización. Como consecuencia, el cálculo inicial de los puntos anotados en cada posesión, basado en la diferencia entre los marcadores al

inicio y al final de la posesión, producía valores incorrectos. En el Anexo se presenta en detalle uno de los casos detectados.

Para subsanar estos inconvenientes, se redefinió el procedimiento de cálculo de los puntos por posesión. En lugar de utilizar el marcador acumulado informado por el sitio web, se reconstruyó el marcador de manera independiente a partir de las acciones registradas en el *play-by-play*. Para ello se consideraron únicamente las tres acciones capaces de modificar el tanteador: TIRO LIBRE ANOTADO (+1 punto), CANASTA DE 2 PUNTOS (+2 puntos) y TRIPLE (+3 puntos). A partir de estas acciones se calcularon de forma acumulativa los puntos convertidos por cada equipo a lo largo de los partidos, obteniéndose marcadores reconstruidos que reemplazaron al obtenido originalmente mediante el proceso de *scraping*.

Como resultado de esta corrección, la variable puntos por posesión pasó a tomar únicamente valores comprendidos entre 0 y 7 puntos, eliminándose los valores imposibles detectados inicialmente.

Es importante destacar que, aún después de estas correcciones, algunas de las posesiones continuaron presentando puntos inusualmente altos, por lo que también se realizó una revisión del contexto de aquellas posesiones con resultados extremos. Mediante lo cual se identificaron inconsistencias en la secuencia cronológica de algunas acciones registradas en el *play-by-play*. En particular, se identificaron situaciones en las que dos acciones de anotación del mismo equipo aparecían de manera consecutiva, sin que existiera una acción intermedia del equipo rival que justificara la continuidad de la posesión. Estas inconsistencias pueden deberse a errores en la carga manual de la información realizada durante el partido y constituyen una limitación inherente a la calidad de los datos disponibles. Si bien estos casos fueron poco frecuentes, generan incertidumbre principalmente en las posesiones con cinco, seis o siete puntos, cuya ocurrencia es muy poco común en condiciones normales de juego.

En este sentido, mientras que en la base de datos utilizada por Damoulaki et al. (2025) las posesiones con más de 3 puntos representan aproximadamente el 0,1 % del total, en la base construida para este trabajo dicha proporción asciende al 0,3 %, lo que podría ser consistente

con la presencia de errores de carga no detectados en la totalidad de los partidos. Sin embargo, no puede descartarse que también responda a la idiosincrasia propia del juego en la Liga Nacional de Básquetbol de Argentina, en comparación con la NBA. Por los alcances de esta tesina, estas observaciones fueron conservadas en la base de datos; esta limitación será retomada en el capítulo de Discusión.

3.3.5 Identificación de jugadores ofensivos y defensivos en cancha

Con el objetivo de poder distinguir la participación individual de los jugadores en cada posesión, se utilizó la información de los quintetos en cancha previamente reconstruidos durante el preprocesamiento. Para cada posesión se identificaron los cinco jugadores del equipo atacante y los cinco jugadores del equipo defensor.

A partir de esta información se construyó una representación matricial de jugadores por posesión, donde cada jugador de la temporada cuenta con dos variables indicadoras. Donde, la primer variable dummy asigna a cada jugador un 1 si el jugador forma parte del quinteto ofensivo y 0 en caso contrario; mientras que la segunda variable dummy asigna un -1 si el jugador forma parte del quinteto defensivo, y 0 en otro caso. Este esquema permite modelar de manera explícita la contribución ofensiva y defensiva de manera independiente para cada uno de los jugadores que han participado en al menos un partido dentro de la temporada en estudio.

3.4 Base de datos final: *poss-by-poss*

A través de este proceso, se generó una base de datos que permitirá modelar la cantidad de puntos por posesión teniendo en cuenta los jugadores presentes en cancha, dicha base cuenta con la información correspondiente a 58.625 posesiones, asociadas a 378 partidos disputados en la temporada en estudio.

Las variables presentes son las siguientes:

puntos = Cantidad de puntos en la posesión.

cuarto = Cuarto en el que se desarrollo la posesión.

tiempo = Tiempo restante del cuarto en el momento que finaliza la acción.

equipo = Nombre del equipo que está atacando en la posesión.

condicion = Condición de localia del equipo que está atacando en la posesión.

Y se cuenta con variables indicadoras referentes a las presencias ofensivas y defensivas al momento de la posesión para cada uno de los jugadores que hayan completado al menos una posesión a lo largo de la temporada. Se encontraron 346 jugadores que cumplían esa condición en esta temporada, contabilizando de esta manera otras 692 (346 indicadoras ofensivas y 346 indicadoras defensivas) variables adicionales dentro del dataset.

4 Metodología

Con el fin de sintetizar adecuadamente la contribución ofensiva y defensiva de los jugadores de manera adecuada, se compararon los resultados provistos por modelos con distintas características. Para identificar cuál de ellos brinda los mejores resultados, se definieron procedimientos adecuados para su evaluación y comparación. Los distintos modelos utilizados, las formas de estimación de sus parámetros y los métodos empleados para compararlos se presentan a continuación.

4.1 Modelos propuestos

4.1.1 Modelo de regresión lineal múltiple

Los modelos más utilizados en la literatura relevante sobre RAPMs son los **modelos de regresión lineal múltiple**, los cuales van a modelar el comportamiento de la variable respuesta *puntos en la posesión i* (Y_i) en función de $P = 2K$ variables explicativas dicotómicas, correspondientes a las apariciones ofensivas y defensivas de K jugadores.

El componente aleatorio supone que las variables respuesta Y_i tienen variancia constante σ^2 . De esta manera tenemos que,

$$\begin{cases} Y_i \sim N(\mu_i, \sigma^2), \\ \mu_i = \beta_0 + \sum_{k=1}^K \beta_k^o x_{ik}^o + \sum_{k=1}^K \beta_k^d x_{ik}^d, \end{cases} \quad (1)$$

para $i = 1, \dots, n$, donde n : es el número total de posesiones disputadas, K : es el número total de jugadores en el análisis, Y_i : es la variable respuesta correspondiente al número de puntos realizados en la posesión i , μ_i : es la cantidad esperada de puntos anotados en la posesión i , x_{ik}^o : indicadora ofensiva del jugador k en la posesión i (1 si el jugador k estaba jugando en ataque en la posesión i , 0 en otro caso), x_{ik}^d : indicadora defensiva del jugador k en la posesión i (-1 si el jugador k estaba jugando en defensa en la posesión i , 0 en otro caso), β_0 : Intercepto del modelo, β_k^o : coeficiente ofensivo del jugador k (ORAPM), β_k^d : coeficiente defensivo del jugador k (DRAPM).

Este modelo es de sencilla aplicación y ha sido ampliamente utilizado por distintos analistas que trabajan con este tipo de métricas. Sin embargo, la variable respuesta en este caso es discreta, tomando valores enteros acotados entre 0 y 7, lo que sugiere que el supuesto de normalidad del modelo de regresión lineal múltiple podría no resultar apropiado para representar adecuadamente la naturaleza de la variable de interés.

4.1.1.1 Interpretación de los coeficientes Las medidas de eficiencia ofensiva (ORAPM) y defensiva (DRAPM) están representadas por los coeficientes asociados a las variables indicadoras ofensivas y defensivas de cada jugador, denotados por β_k^o y β_k^d , respectivamente. Estos coeficientes cuantifican el aporte marginal esperado de cada jugador sobre la cantidad de puntos anotados por posesión.

Un mayor valor en el coeficiente ORAPM está asociado a una mayor cantidad de puntos anotados esperados por posesión. Por otra parte, debido a que las variables defensivas fueron codificadas con valores 0 y -1, un valor mayor del DRAPM está asociado a una menor cantidad esperada de

puntos recibidos. Por lo tanto, en ambos casos, valores mayores representan una contribución más favorable al rendimiento del equipo.

La comparación entre dos jugadores resulta muy útil e intuitiva a la hora de querer dilucidar esta interpretación. En particular, la diferencia entre dos coeficientes representa el cambio esperado en la cantidad de puntos anotados por posesión cuando un jugador reemplaza a otro, manteniendo constantes todos los demás jugadores presentes en cancha. Esta interpretación puede ilustrarse mediante el siguiente ejemplo.

Sean dos quintetos: el quinteto ofensivo A $(a_1, a_2, a_3, a_4, a_5)$ y el quinteto defensivo B $(b_1, b_2, b_3, b_4, b_5)$. Donde la cantidad esperada de puntos anotados por el equipo atacante viene dada por

$$\mu_1 = \beta_0 + \beta_{a_1}^o + \beta_{a_2}^o + \beta_{a_3}^o + \beta_{a_4}^o + \beta_{a_5}^o - \beta_{b_1}^d - \beta_{b_2}^d - \beta_{b_3}^d - \beta_{b_4}^d - \beta_{b_5}^d.$$

Si se asume que el jugador a_6 reemplaza al jugador a_1 , manteniéndose sin modificaciones los restantes nueve jugadores. En ese caso, la cantidad esperada de puntos se modifica a:

$$\mu_2 = \beta_0 + \beta_{a_6}^o + \beta_{a_2}^o + \beta_{a_3}^o + \beta_{a_4}^o + \beta_{a_5}^o - \beta_{b_1}^d - \beta_{b_2}^d - \beta_{b_3}^d - \beta_{b_4}^d - \beta_{b_5}^d.$$

Entonces $\mu_2 - \mu_1 = \beta_{a_6}^o - \beta_{a_1}^o$ representa la diferencia de puntos esperados anotados por el equipo A cuando el jugador a_6 reemplaza al jugador a_1 , y todos los demás jugadores se mantienen constantes. De esta manera, si $\beta_{a_6}^o > \beta_{a_1}^o$ se espera que el equipo atacante anote una mayor cantidad de puntos por posesión con el jugador a_6 en cancha, por lo que su contribución ofensiva resulta mayor.

De manera análoga, para la interpretación de los coeficientes defensivos, si el jugador b_6 reemplaza al jugador b_1 la cantidad esperada de puntos anotados por el equipo atacante pasa a ser

$$\mu_3 = \beta_0 + \beta_{a_1}^o + \beta_{a_2}^o + \beta_{a_3}^o + \beta_{a_4}^o + \beta_{a_5}^o - \beta_{b_6}^d - \beta_{b_2}^d - \beta_{b_3}^d - \beta_{b_4}^d - \beta_{b_5}^d.$$

entonces $\mu_3 - \mu_1 = -\beta_{b_6}^d + \beta_{b_1}^d$ representa la diferencia de puntos esperados recibidos por el equipo B cuando el jugador b_6 reemplaza al jugador b_1 , y todos los demás jugadores se mantienen constantes. De esta manera, si $\beta_{b_6}^d$ es mayor a $\beta_{b_1}^d$, la cantidad esperada de puntos recibidos será menor y la contribución defensiva del jugador b_6 será mayor que la del jugador b_1 .

4.1.2 Modelo logístico multinomial

Si bien el modelo de regresión lineal permite obtener una interpretación directa de los efectos ofensivos y defensivos de los jugadores, como se mencionó anteriormente, la variable respuesta considerada en este trabajo es discreta. En este sentido, resulta de interés considerar una especificación alternativa que contemple esta característica, por lo que se implementan modelos de **regresión logística multinomial**.

Recordando que Y_i es igual a la cantidad de puntos en una posesión, nuestra nueva variable respuesta resulta

$$Y_i^M = \begin{cases} Y_i, & \text{para } Y_i \in \{0, 1, 2\} \\ 3, & \text{para } Y_i \geq 3. \end{cases} \quad (2)$$

Para representar formalmente la respuesta multinomial, se define el vector de variables indicadoras

$$\mathbf{Y}_i = (Y_{i0}, Y_{i1}, Y_{i2}, Y_{i3}),$$

donde $Y_{ic} = 1$ si $Y_i^M = c$ y $Y_{ic} = 0$ en otro caso. Por lo tanto,

$$\mathbf{Y}_i \sim \text{Multinomial}(1, \boldsymbol{\pi}_i),$$

con $\boldsymbol{\pi}_i = (\pi_{i0}, \pi_{i1}, \pi_{i2}, \pi_{i3})$ y $\sum_{c=0}^3 \pi_{ic} = 1$.

Resultando $\pi_{i0}, \pi_{i1}, \pi_{i2}$ y π_{i3} las probabilidades respectivas de no anotar, de anotar 1 punto, de anotar 2 puntos y de anotar 3 puntos o más en la posesión i .

Luego construimos el modelo logístico multinomial con categoría de referencia, eligiendo como categoría de referencia a 0 puntos anotados:

$$\log\left(\frac{\pi_{ic}}{\pi_{i0}}\right) = \beta_{0c} + \sum_{k=1}^K \beta_{kc}^o x_{ik}^o + \sum_{k=1}^K \beta_{kc}^d x_{ik}^d \quad \text{con } c \in \{1, 2, 3\}. \quad (3)$$

Dicho modelo describe el efecto de los jugadores en cada uno de los tres logits correspondientes a las categorías diferentes de cero, permitiendo calcular el aporte ofensivo y defensivo de cada jugador para cada tipo de anotación.

Las probabilidades multinomiales vienen dadas por las siguientes ecuaciones

$$\pi_{ic} = \frac{\exp(\mathbf{x}_i^T \boldsymbol{\beta}_c)}{1 + \sum_{h=1}^3 \exp(\mathbf{x}_i^T \boldsymbol{\beta}_h)}, \quad c \in \{1, 2, 3\}, \quad (4)$$

con $\boldsymbol{\beta}_0 = \mathbf{0}$.

4.1.2.1 Interpretación de los coeficientes Para cada jugador k , un mayor valor en los coeficientes ofensivos $(\beta_{k1}^o, \beta_{k2}^o, \beta_{k3}^o)$ se encuentra asociado a un mayor valor en la razón de *odds* de anotar 1, 2 o 3 puntos o más, respecto de no anotar. Mientras que a valores más grandes en los coeficientes defensivos $(\beta_{k1}^d, \beta_{k2}^d, \beta_{k3}^d)$, menor será cada una de las respectivas razones de *odds* mencionadas.

De igual manera, como el objetivo de esta tesina está centrado en obtener una medida única que resuma la contribución de un jugador en el desempeño ofensivo y defensivo de su equipo, estos coeficientes no se interpretan de manera individual, sino que sirven como base para la construcción de una métrica unificada.

4.2 EPTS y wEPTS

4.2.1 *Expected points* (EPTS)

En el enfoque mencionado anteriormente los coeficientes representan las contribuciones de cada jugador en los distintos tipos de anotación. Aunque puede resultar interesante y permita realizar diversos tipos de análisis, el objetivo final de este estudio es obtener una métrica que unifique la contribución ofensiva y defensiva en una única medida general.

A diferencia del modelo de regresión lineal múltiple, el cambio en la cantidad esperada de puntos al sustituir un jugador por otro no sólo está determinado por los coeficientes de ambos jugadores, sino también por los coeficientes de sus cuatro compañeros y de los cinco jugadores rivales. Por lo tanto, siguiendo la estrategia propuesta por Damoulaki et al. (2025), se evalúa a cada jugador bajo un escenario simplificado. En este escenario, el único jugador con coeficiente distinto de cero es el jugador de interés, mientras que todos los demás jugadores presentes en cancha pertenecen al grupo de referencia, es decir, poseen coeficientes iguales a cero. De este modo, la cantidad esperada de puntos por posesión refleja exclusivamente la contribución ofensiva o defensiva del jugador evaluado.

La contribución ofensiva se obtiene calculando la cantidad de puntos esperada por posesión que anota el equipo de dicho jugador cuando él está incluido ofensivamente, bajo el escenario simplificado. De manera similar, la contribución defensiva de un jugador se obtiene mediante la cantidad esperada de puntos concedidos por posesión por el equipo de dicho jugador cuando él está en la alineación y todos los demás jugadores en cancha pertenecen al grupo de referencia. A esta nueva métrica la denominamos *Expected Points* (EPTS).

$$EPTS_k^r = E(Y_i \mid X_{ik}^r \neq 0, \mathbf{X}_{i \setminus k}^r = \mathbf{0}, \mathbf{X}_i^{\bar{r}} = \mathbf{0}), \quad r \in \{o, d\}. \quad (5)$$

Estas dos medidas, $EPTS^o$ y $EPTS^d$, son funciones de los coeficientes ofensivos y defensivos del modelo multinomial ajustado. Se obtienen mediante

$$EPTS_k^r = \pi_{k1}^r + 2\pi_{k2}^r + 3,0304\pi_{k3}^r, \quad r \in \{o, d\}, \quad (6)$$

donde π_{kc}^o son las probabilidades estimadas mediante un modelo de regresión logística multinomial de anotar uno, dos o tres puntos o más, respectivamente, por posesión del equipo del jugador k , cuando este se encuentra incluido en la alineación y tanto sus compañeros como los jugadores del equipo rival pertenecen al grupo de referencia, es decir, presentan coeficientes iguales a cero. De manera similar, π_{kc}^d son las probabilidades de que el equipo oponente al del jugador k anoten uno, dos o tres puntos o más, respectivamente, por posesión, cuando dicho jugador está incluido en la alineación y el resto de los jugadores pertenecen al grupo de referencia. Estas probabilidades vienen dadas por:

$$\pi_{kc}^r = \frac{\exp(\mu_{kc}^r)}{1 + \exp(\mu_{k1}^r) + \exp(\mu_{k2}^r) + \exp(\mu_{k3}^r)} \quad \text{con } \mu_{kc}^o = \beta_{0c} + \beta_{kc}^o \quad \text{y } \mu_{kc}^d = \beta_{0c} - \beta_{kc}^d.$$

El valor de la categoría “3 puntos o más” corresponde al promedio empírico de puntos en esta categoría superior a partir de la distribución observada:

$$\frac{3(8134) + 4(143) + 5(45) + 6(6) + 7(1)}{8134 + 143 + 45 + 6 + 1} = 3,0304.$$

Finalmente se obtiene una medida de desempeño ofensivo y defensivo para cada jugador, donde un mayor valor de $EPTS^o$ indica una mayor cantidad esperada de puntos anotados por posesión cuando el jugador participa ofensivamente, mientras que un menor valor de $EPTS^d$ representa una menor cantidad esperada de puntos concedidos por posesión cuando el jugador integra el equipo defensor.

4.2.2 *Weighted expected points* (wEPTS)

Una versión ponderada de los EPTS es propuesta por Damoulaki et al. (2025), la cual tiene en cuenta la participación del jugador a lo largo de la temporada. Para ello, la métrica anteriormente

presentada se pondera según la proporción de posesiones de su equipo en las que el jugador de interés estuvo en cancha. De esta manera, el EPTS ponderado (wEPTS) se define como:

$$\begin{aligned}
wEPTS_k^r &= E(Y_i \mid \mathbf{X}_{i \setminus k}^r = \mathbf{0}, \mathbf{X}_i^{\bar{r}} = \mathbf{0}, T_i^r = t_k) \\
&= P(X_{ik}^r \neq 0 \mid T_i^r = t_k) E(Y_i \mid X_{ik}^r \neq 0, \mathbf{X}_{i \setminus k}^r = \mathbf{0}, \mathbf{X}_i^{\bar{r}} = \mathbf{0}) \\
&\quad + P(X_{ik}^r = 0 \mid T_i^r = t_k) E(Y_i \mid X_{ik}^r = 0, \mathbf{X}_{i \setminus k}^r = \mathbf{0}, \mathbf{X}_i^{\bar{r}} = \mathbf{0}) \\
&= W_k^r EPTS_k^r + (1 - W_k^r) EPTS_0,
\end{aligned} \tag{7}$$

donde $r \in \{o, d\}$.

$EPTS_0$ representa la cantidad esperada de puntos por posesión bajo el escenario en el que todos los jugadores presentes en cancha pertenecen al grupo de referencia. Dado que en este escenario todos los coeficientes ofensivos y defensivos asociados a los jugadores son iguales a cero, este valor depende únicamente de los interceptos del modelo y es el mismo tanto para la evaluación ofensiva como defensiva. De esta manera,

$$EPTS_0 = \frac{\exp(\beta_{01}) + 2\exp(\beta_{02}) + 3,0304\exp(\beta_{03})}{1 + \exp(\beta_{01}) + \exp(\beta_{02}) + \exp(\beta_{03})}. \tag{8}$$

Por su parte, el peso W_k^r se estima como:

$$\hat{W}_k^r = \frac{n_k^r}{n_{t_k}^r} = \frac{\sum_{i=1}^n \mathcal{I}(X_{ik}^r \neq 0)}{\sum_{i=1}^n \mathcal{I}(T_i^r = t_k)}, \tag{9}$$

donde $\mathcal{I}(A)$ es una variable indicadora que vale 1 en caso de que A sea verdadero y 0 en caso contrario, T_i^r es el equipo en ataque ($r = o$) o en defensa ($r = d$) en la posesión i, t_k es el equipo del jugador k , n_k^r es el número de posesiones en las que el jugador k participó en el quinteto en ataque o defensa en la temporada y $n_{t_k}^r$ es el número de posesiones en las que el equipo del jugador k estuvo en ataque o defensa en la temporada.

4.3 Estimación de los RAPMs

4.3.1 Método de mínimos cuadrados

En el modelo de regresión lineal múltiple, los parámetros se van a estimar mediante el método de mínimos cuadrados, siendo la función a minimizar:

$$S = \sum_{i=1}^n (y_i - \mu_i)^2. \quad (10)$$

Los estimadores de β_l se definen como aquellos que minimizan la suma de cuadrados S , y se denotan como $\hat{\beta}_0, \dots, \hat{\beta}_P$.

Obteniendo de esta manera los siguientes coeficientes estimados:

$$\hat{\beta}_l = \frac{\sum_{i=1}^n x_{il}^* y_i}{\sum_{i=1}^n (x_{il}^*)^2}, \quad (11)$$

para $l = 0, \dots, P$, donde x_{il}^* son los valores de la l -ésima variable explicativa x_l después de haber sido ajustada por todas las demás variables explicativas $x_0, \dots, x_P$ excepto x_l . La variable explicativa ajustada x_l^* es aquella parte de x_l que no puede ser explicada mediante una regresión sobre las otras variables explicativas (Dunn y Smyth, 2018).

4.3.2 Método de máxima verosimilitud

En el modelo logístico multinomial, los parámetros asociados a las distintas categorías de respuesta se estiman conjuntamente a partir de las tres ecuaciones logit. En general, las estimaciones de máxima verosimilitud se obtienen maximizando la log-verosimilitud multinomial,

$$L_m(\beta, \mathbf{y}) = \sum_{i=1}^n \sum_{c=0}^3 y_{ic} \log(\pi_{ic}), \quad (12)$$

o equivalentemente minimizando la log-verosimilitud negativa ($-L_m(\boldsymbol{\beta}, \mathbf{y})$).

A diferencia del modelo lineal estimado mediante mínimos cuadrados ordinarios, la estimación de los coeficientes del modelo logístico multinomial no posee una solución cerrada, por lo que debe recurrirse a algoritmos iterativos para obtener los resultados. En este trabajo, dichos modelos se ajustaron mediante la librería `glmnet` del software estadístico R, la cual utiliza algoritmos de descenso cíclico por coordenadas para minimizar la función objetivo penalizada.

4.4 Multicolinealidad

En los modelos de regresión múltiple, la multicolinealidad hace referencia a la existencia de dependencias lineales o casi lineales entre las columnas de la matriz de diseño. Cuando estas dependencias son exactas, la matriz $X'X$ resulta singular y los parámetros no pueden estimarse mediante mínimos cuadrados ordinarios. Cuando las dependencias son aproximadas, las estimaciones pueden calcularse, pero presentando variancias grandes, dando lugar a coeficientes muy inestables y sensibles a cambios relativamente pequeños en los datos.

En los modelos RAPM la multicolinealidad aparece de manera natural debido a la estructura propia del juego. Donde, al tener muchos jugadores que comparten una gran proporción de sus minutos en cancha con los mismos compañeros, se genera una fuerte dependencia entre las columnas correspondientes a la matriz de diseño, como puede identificarse en el Cuadro 4. Como resultado, el modelo dispone de poca información para distinguir cuál de los jugadores es realmente responsable del rendimiento observado durante esas posesiones.

Este problema resulta especialmente relevante en la Liga Nacional de Básquetbol de Argentina, donde la cantidad de observaciones disponibles es considerablemente menor que en competencias como la NBA, donde la cantidad de partidos disputados por cada equipo y la duración de los mismos es mayor.

Cuadro 4: Pares de jugadores que compartieron la mayor proporción de posesiones durante la temporada regular.

Jugador A	Jugador B	Posesiones juntos	% de A con B	% de B con A	Correlación ofensiva
BARREIRO, A.	BROCAL, A.	3.893	80.9	84.1	0.819
BRUSSINO, J.	MILLER, T.	2.753	81.2	79.9	0.800
ANDUJAR, L.	THORNTON, W.	3.302	77.9	81.2	0.788
LUGARINI, B.	VILDOZA, L.	2.629	77.3	79.6	0.779
THOMAS JR, M.	THORNTON, W.	3.132	78.4	77.0	0.769
POMOLI LARRABURU, N.	VILDOZA, L.	2.507	77.3	75.9	0.759
DEFELIPPO, J.	SHRIVER, D.	3.084	76.6	75.7	0.755
BARRAL, P.	MATA, M.	2.874	75.7	75.3	0.747
LUGARINI, B.	POMOLI LARRABURU, N.	2.533	74.5	78.1	0.757
CABRERA, M.	VALLEJOS, R.	3.038	78.9	74.1	0.757

Para abordar este problema, tal como se mencionó en la Sección 2.3, los distintos autores que trabajaron con este tipo de modelos recurrieron a estimaciones basadas en métodos de regularización mediante los cuales se introduce deliberadamente un pequeño sesgo en las estimaciones con el objetivo de reducir su varianza. Este compromiso entre sesgo y varianza suele traducirse en una disminución del error de predicción y en estimaciones considerablemente más estables. Por otra parte, diversos autores destacaron las ventajas de disponer de una mayor cantidad de datos, incorporando en muchos casos información de varias temporadas. Sin embargo, esta estrategia no pudo implementarse en el presente trabajo, ya que, una vez finalizada cada temporada de la Liga Nacional de Básquetbol de Argentina, los enlaces a los partidos dejan de estar disponibles, imposibilitando el acceso a la información histórica necesaria para reconstruir las bases de datos.

4.5 Tratamiento de los jugadores con poco tiempo de juego (*Low time players - LTP*)

En el presente trabajo se identificaron 346 jugadores que participaron en al menos una posesión a lo largo de la temporada, lo que representa un promedio de 17,3 jugadores utilizados por equipo. La distribución de posesiones presenta una marcada asimetría, tal como se observa en

la Figura 10, observándose jugadores que participaron en apenas una o dos posesiones, mientras que otros, titulares indiscutibles, participaron en más de 4000 posesiones.




Figura 8: Distribución de posesiones disputadas por jugador

Como se mencionó en la sección 2.3, las estimaciones de los coeficientes de jugadores que juegan muy poco, y por lo tanto, cuentan con muy pocas observaciones en la base, se ven fuertemente afectadas y presentan coeficientes extremos. Para intentar solucionar esta problemática, dentro de la literatura relevante sobre RAPM, se han definido distintos criterios de exclusión de jugadores en base a la cantidad de minutos que disputaron en las temporadas analizadas.

Rosenbaum (2004) propone excluir a los jugadores con menos de 250 minutos disputados, mientras que Ilardi (2007) e Ilardi y Barzilai (2008) utilizan un umbral de 400 minutos. Sill (2010) evalúa distintos puntos de corte, comprendidos entre 800 y 1200 minutos, seleccionando el más adecuado mediante validación cruzada. En un enfoque diferente, Gong y Chen (2024) no eliminan a estos jugadores, sino que agrupan a aquellos con menos de 10 minutos por partido en una categoría específica, representando al 20% del total de jugadores, y les asignan un prior particular dentro de su modelo bayesiano. Mientras que en el artículo de referencia de este

trabajo, Damoulaki et al. (2025) excluye a los jugadores con menos de 200 minutos, lo que representa el 32% de los jugadores de su base de datos.

Considerando los antecedentes presentados y dado que la posesión constituye la unidad de análisis utilizada en los modelos RAPM desarrollados en este trabajo, se decidió definir el criterio de exclusión en función de la cantidad de posesiones disputadas por cada jugador, en lugar de los minutos jugados. En particular, se excluyeron aquellos jugadores que participaron en menos de 500 posesiones durante la temporada, lo que representa 117 jugadores (33,8 % del total).

Cabe destacar que la exclusión de jugadores con poco tiempo de juego no elimina completamente este problema de sobreestimación de coeficientes, ya que continúan existiendo diferencias importantes en la cantidad de observaciones disponibles para cada jugador. Por este motivo, además del criterio de exclusión adoptado, en los modelos propuestos se emplean métodos de regularización, los cuales penalizan la magnitud de los coeficientes estimados cuando la información disponible resulta insuficiente.

4.6 Métodos de regularización

El modelo planteado presenta variables predictoras altamente correlacionadas debido a que muchos de los jugadores comparten gran parte del tiempo en cancha, por lo que el ajuste con mínimos cuadrados ordinarios o mediante máxima verosimilitud se torna inestable. Con el objetivo de abordar este problema, se realizaron estimaciones mediante métodos de regularización (o *shrinkage*), los cuales incorporan un término de penalización a la función de pérdida para de esta manera controlar la magnitud de los coeficientes estimados. Esta técnica provoca que las estimaciones sean sesgadas, pero a cambio de una notable reducción en la variancia (James, G., Witten, D., Hastie, T., & Tibshirani, R. (2021)).

En el caso de los modelos logísticos multinomiales, cada variable explicativa posee un coeficiente asociado a cada una de las tres ecuaciones logit. En su implementación mediante la librería `glmnet` se utilizó una penalización agrupada, de modo que los tres coeficientes correspondientes

a una misma variable explicativa se consideran como un único grupo. Esta característica resulta relevante para las penalizaciones que incorporan un componente L_1 , ya que las variables explicativas permanecen activas o se anulan simultáneamente en las tres categorías de respuesta.

4.6.1 Regresión Ridge o Regularización L_2

El método más utilizado en la bibliografía relevante sobre RAPM es la regresión Ridge. Esta técnica, propuesta originalmente por Hoerl y Kennard (1970), incorpora una penalización cuadrática (L_2) sobre los coeficientes del modelo.

Para el modelo de regresión lineal múltiple los coeficientes estimados $\hat{\beta}$ se obtienen minimizando la función de pérdida (S) modificada de la siguiente manera:

$$S^* = \sum_{i=1}^n (y_i - \mu_i)^2 + \lambda \sum_{l=1}^P \beta_l^2 = S + \lambda \sum_{l=1}^P \beta_l^2 \quad (13)$$

Al igual que en mínimos cuadrados ordinarios, la regresión Ridge busca coeficientes estimados que ajusten bien a los datos, minimizando la suma de cuadrados del error. Por otro lado, el segundo término, $\lambda \sum_{l=1}^P \beta_l^2$ es menor cuando $\beta_1, \dots, \beta_P$ son más cercanos a cero. De esta manera este término penalizador tiene el efecto de contraer los coeficientes estimados hacia cero.

El *trade-off* entre estos dos criterios es controlado por el hiperparámetro $\lambda \geq 0$, el cual controla el efecto relativo de estos dos términos en los coeficientes de regresión estimados. La estimación será igual a la de mínimos cuadrados cuando $\lambda = 0$ (no hay penalización) y a medida que λ aumenta, la penalización se vuelve más dominante y los coeficientes tienden a 0.

Por otro lado, en el caso del modelo logístico multinomial, el parámetro de penalización se agrega a la función de log-verosimilitud, de manera tal que la función a minimizar resulta:

$$L_m^*(\beta, \mathbf{y}) = - \sum_{i=1}^n \sum_{c=0}^3 y_{ic} \log(\pi_{ic}) + \lambda \sum_{l=1}^P \sum_{c=1}^3 \beta_{lc}^2 = -L_m(\beta, \mathbf{y}) + \lambda \sum_{l=1}^P \sum_{c=1}^3 \beta_{lc}^2, \quad (14)$$

en ambos casos el valor del λ se selecciona mediante validación cruzada. Cabe destacar que,

a diferencia de lo que ocurre con la penalización L1 (Sección 6.6.2), la agrupación de los tres coeficientes de un mismo jugador no introducen ninguna diferencia en la penalización Ridge.

Una característica de la penalización L_2 es que, en general, no produce coeficientes exactamente iguales a cero para valores finitos de λ . Esto se debe a que la función de penalización (β_l^2) es suave y diferenciable en cero, por lo que no existe un cambio abrupto en el criterio de optimización cuando un coeficiente alcanza dicho valor. En consecuencia, Ridge reduce la magnitud de los efectos estimados pero conserva habitualmente a todos los predictores dentro del modelo.

4.6.2 Lasso o Regularización L_1

La técnica Lasso, propuesta por Tibshirani (1996), constituye una alternativa a Ridge que, además de contraer la magnitud de los coeficientes, puede llevar algunos de ellos exactamente a cero. De esta manera, el método realiza simultáneamente regularización y selección de variables. La intención de aplicar esta técnica está basada en su posible utilidad para abordar el problema de los coeficientes extremos que presentan los jugadores que juegan pocos minutos. A diferencia de la penalización cuadrática utilizada por Ridge, Lasso incorpora una penalización L_1 , basada en la suma de los valores absolutos de los coeficientes. Para el modelo de regresión lineal múltiple la función de pérdida resulta:

$$S^* = \sum_{i=1}^n (y_i - \mu_i)^2 + \lambda \sum_{l=1}^P |\beta_l| = S + \lambda \sum_{l=1}^P |\beta_l|. \quad (15)$$

En esta técnica se presenta la función ($|\beta_l|$), la cual no es diferenciable en cero y presenta un punto anguloso en dicho valor. Esta característica permite que, para determinados valores de λ , el mínimo de la función objetivo se alcance exactamente en $\beta_l = 0$. En su interpretación geométrica, la restricción L_1 presenta vértices sobre los ejes correspondientes a coeficientes nulos, mientras que la restricción L_2 de Ridge posee una superficie suave. Como consecuencia, Lasso no solo contrae los coeficientes, sino que puede anular completamente algunos de ellos. En este caso valores grandes de λ incrementan la penalización, llevando a que un mayor número de

coeficientes se reduzcan exactamente a cero.

Por otro lado, considerando la penalización agrupada mencionada al inicio de esta sección, en el modelo logístico multinomial la penalización L1 no se aplica a cada coeficiente individualmente, sino a la norma L2 del vector formado por los tres coeficientes asociados a cada jugador. Esta variante se conoce en la literatura como *group lasso* (Yuan & Lin, 2006), y resulta en:

$$L_m^*(\boldsymbol{\beta}, \mathbf{y}) = -\sum_{i=1}^n \sum_{c=0}^3 y_{ic} \log(\pi_{ic}) + \lambda \sum_{l=1}^P \sqrt{\beta_{l1}^2 + \beta_{l2}^2 + \beta_{l3}^2} = -L_m(\boldsymbol{\beta}, \mathbf{y}) + \lambda \sum_{l=1}^P \sqrt{\beta_{l1}^2 + \beta_{l2}^2 + \beta_{l3}^2}. \quad (16)$$

En este caso, al tratarse de una penalización agrupada, la anulación ocurre a nivel de grupo, donde los tres coeficientes asociados a un mismo predictor $(\beta_{l1}, \beta_{l2}, \beta_{l3})$ se anulan de manera conjunta, o ninguno de ellos lo hace.

4.6.3 Elastic Net

Lasso presenta una limitación relevante cuando existen grupos de predictores fuertemente correlacionados. En estas situaciones puede seleccionar uno de ellos y contraer los restantes a cero, aun cuando varios contengan información similar sobre la variable respuesta. Como consecuencia, pequeñas modificaciones en los datos pueden cambiar cuál de las variables correlacionadas se contrae a cero.

Elastic Net, propuesto por Zou y Hastie (2005), combina las penalizaciones L_1 y L_2 con el objetivo de reunir las principales propiedades de ambos métodos. La componente L_1 permite anular algunos coeficientes y, por lo tanto, realizar selección de variables. La componente L_2 , en cambio, favorece que predictores altamente correlacionados reciban coeficientes similares, evitando que el modelo seleccione arbitrariamente uno de ellos y elimine al resto.

Esta característica resulta particularmente apropiada para los modelos RAPM, donde es habitual encontrar jugadores que comparten una proporción elevada de sus posesiones. Frente

a este escenario, Elastic Net permite evitar en cierta medida la selección arbitraria de uno solo de los jugadores realizada por Lasso, sin renunciar completamente a la capacidad de producir coeficientes nulos. Para el modelo de regresión lineal múltiple la función de pérdida viene dada por:

$$S^* = \sum_{i=1}^n (y_i - \mu_i)^2 + \lambda \left[\alpha \sum_{l=1}^P |\beta_l| + \frac{(1-\alpha)}{2} \sum_{l=1}^P \beta_l^2 \right] = S + \lambda \left[\alpha \sum_{l=1}^P |\beta_l| + \frac{(1-\alpha)}{2} \sum_{l=1}^P \beta_l^2 \right], \quad (17)$$

mientras que para el modelo logístico multinomial resulta:

$$\begin{aligned} L_m^*(\boldsymbol{\beta}, \mathbf{y}) &= - \sum_{i=1}^n \sum_{c=0}^3 y_{ic} \log(\pi_{ic}) + \lambda \left[\alpha \sum_{l=1}^P \sqrt{\beta_{l1}^2 + \beta_{l2}^2 + \beta_{l3}^2} + \frac{(1-\alpha)}{2} \sum_{l=1}^P \sum_{c=1}^3 \beta_{lc}^2 \right] \\ &= -L_m(\boldsymbol{\beta}, \mathbf{y}) + \lambda \left[\alpha \sum_{l=1}^P \sqrt{\beta_{l1}^2 + \beta_{l2}^2 + \beta_{l3}^2} + \frac{(1-\alpha)}{2} \sum_{l=1}^P \sum_{c=1}^3 \beta_{lc}^2 \right], \end{aligned} \quad (18)$$

donde, λ controla la intensidad de la regularización, mientras que $\alpha \in [0, 1]$ determina cuánto peso se asigna a cada penalización. Para $\alpha = 0$ se obtiene Ridge y para $\alpha = 1$ se obtiene Lasso. Los valores intermedios permiten distintos compromisos entre contracción y selección de variables.

4.7 Selección de hiperparámetros óptimos

Los modelos que incorporan técnicas de regularización (*Ridge*, *Lasso* y *Elastic Net*) requieren la selección de uno o más hiperparámetros que controlan la intensidad de la penalización. En particular, *Ridge* y *Lasso* dependen únicamente del parámetro de regularización λ , mientras que *Elastic Net* incorpora además el parámetro α , que determina la combinación entre las penalizaciones L_1 y L_2 .

La selección de estos hiperparámetros se realizó mediante una búsqueda exhaustiva (*Grid*

Search) sobre un conjunto predefinido de valores candidatos. Para cada combinación de hiperparámetros se ajustó el modelo utilizando validación cruzada de 10 particiones (*10-Fold Cross-Validation*), seleccionándose aquella que minimizó el error cuadrático medio en la regresión lineal múltiple y el *deviance* en la regresión logística multinomial, calculados como el promedio de dichas métricas sobre los conjuntos de validación.

Es importante resaltar que se decidió asignar **partidos completos** dentro de cada partición. De este modo, las posesiones de un mismo encuentro no quedan repartidas entre entrenamiento y validación. Las particiones generadas se replicaron exactamente para la selección de hiperparámetros en cada uno de los modelos.

4.8 Comparación de modelos

Una vez obtenidos los rankings de jugadores a través de las distintas técnicas mencionadas, resulta sumamente importante establecer criterios que permitan compararlos y, de esta manera, poder identificar cuál es el que ofrece mejores resultados.

En primera instancia, se evalúa la bondad de ajuste de los distintos modelos mediante medidas de error y procedimientos de validación basados en simulación. De manera complementaria, se realizan comparaciones a través de estrategias propuestas en artículos relevantes dentro de la literatura de RAPM, buscando evaluar la **consistencia** y la **validez** de los rankings generados.

Particularmente, en el ámbito del fútbol, el profesor Lars Magnus Hvattum plantea una estrategia muy interesante para la comparación de modelos, la cual no parece haber sido implementada en básquetbol hasta la fecha. En el artículo *Modelling the financial contribution of soccer players to their clubs* (Sæbø & Hvattum, 2019) y en videos de su canal de YouTube Football Player Ratings se definen dos criterios diferentes para medir los distintos sistemas de rankings. En este trabajo se replica esta metodología para medir la consistencia de los modelos realizados, mientras que, para evaluar su validez, se recurre a criterios de validación externa, tomando como referencia la propuesta de Damoulaki et al. (2025) pero adaptándola a la información disponible en la Liga Nacional de Básquet Argentina.

4.8.1 Bondad de ajuste

4.8.1.1 Raíz del error cuadrático medio (RMSE) Con el objetivo de evaluar el desempeño predictivo, se compararon los distintos modelos utilizando como criterio principal a la raíz del error cuadrático medio (*Root Mean Squared Error*, RMSE).

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}, \quad (19)$$

donde y_i representa el valor observado y $\hat{y}_i$ el valor predicho por el modelo.

En el enfoque clásico basado en regresión normal, la variable respuesta corresponde a los puntos anotados en cada posesión y se modela como una variable continua:

$$Y_i \sim N(\mu_i, \sigma^2),$$

donde Y_i representa los puntos anotados en la posesión i , mientras que μ_i corresponde al valor esperado de puntos en la posesión i .

Por otro lado, el modelo multinomial considera explícitamente la naturaleza discreta de la variable respuesta. En este caso, para cada posesión i , el modelo estima las probabilidades:

$$P(Y_i^M = c) = \pi_{ic}, \quad \text{con } c \in \{0, 1, 2, 3\},$$

donde π_{ic} representa la probabilidad estimada de anotar c puntos en la posesión i .

En este caso como no se cuenta con un valor de y predicho para calcular el RMSE, es posible, a partir de sendas probabilidades estimadas, obtener el valor esperado de puntos por posesión de la siguiente manera:

$$E(Y_i) = 0\pi_{i0} + 1\pi_{i1} + 2\pi_{i2} + 3,0304\pi_{i3}.$$

Y por lo tanto,

$$\hat{y}_i = 0\hat{\pi}_{i0} + 1\hat{\pi}_{i1} + 2\hat{\pi}_{i2} + 3,0304\hat{\pi}_{i3}.$$

De esta forma, tanto el modelo normal como el multinomial producen una predicción continua del número esperado de puntos por posesión, permitiendo comparar ambos enfoques mediante el RMSE.

4.8.1.2 Simulación del modelo multinomial Se realizó una validación adicional basada en simulaciones del modelo multinomial. El objetivo de este procedimiento es verificar si el modelo reproduce adecuadamente la distribución empírica de puntos por posesión.

Para cada posesión i , el modelo estima un vector de probabilidades:

$$\boldsymbol{\pi}_i = (\pi_{i0}, \pi_{i1}, \pi_{i2}, \pi_{i3}),$$

que representa las probabilidades de anotar 0, 1, 2 o 3 o más puntos, respectivamente.

Posteriormente, para cada posesión se genera aleatoriamente un resultado según dichas probabilidades. Por ejemplo, si para una posesión determinada el modelo estima:

$$\hat{\boldsymbol{\pi}}_i = (0.58, 0.03, 0.27, 0.12),$$

entonces el valor simulado para dicha posesión será:

$$Y_i^{sim} = \begin{cases} 0 & \text{con probabilidad } 0,58, \\ 1 & \text{con probabilidad } 0,03, \\ 2 & \text{con probabilidad } 0,27, \\ 3^+ & \text{con probabilidad } 0,12. \end{cases}$$

Este procedimiento se repite para todas las posesiones del conjunto de datos, obteniendo así un conjunto completo de posesiones simuladas. Luego, el proceso completo se replica múltiples veces (en este caso, 1000 simulaciones independientes).

El objetivo de esta metodología es evaluar si el modelo multinomial es capaz de reproducir adecuadamente la distribución observada de puntos por posesión. Para ello, se comparan las frecuencias relativas simuladas y observadas de cada categoría de anotación.

4.8.2 Evaluación de la consistencia de los resultados

Según Hvattum, un buen modelo producirá resultados similares independientemente de qué partidos hayan sido incluidos en el dataset. Bajo este enfoque, si un mismo sistema de rankings brinda estimaciones de RAPMs similares al ser aplicado a distintas muestras del dataset (de tamaños similares), entonces dicho modelo será consistente.

Para evaluar esto, se divide el conjunto de datos completo en dos particiones con cantidades similares de posesiones. Luego, se calculan las métricas de los jugadores para cada partición y se estima la correlación de Pearson entre ambos conjuntos de coeficientes. Cuanto mayor sea este coeficiente, mayor será la consistencia del modelo.




Figura 9: Procedimiento para evaluar la consistencia de los modelos RAPM.
Fuente: Hvattum (2023), *How to evaluate football player ratings?* [Video]. YouTube.

4.8.3 Criterios de validación externa

Con el objetivo de evaluar la validez de los rankings obtenidos mediante los distintos modelos, se utilizaron una serie de criterios de validación externa. Estos criterios se consideran externos y “objetivos” debido a que se construyen a partir de información independiente de la utilizada para el ajuste de los modelos, por lo que permiten evaluar la capacidad de las métricas para identificar a jugadores reconocidos por su buen desempeño.

El conjunto de criterios elegidos fue el siguiente:

- *Criterio de jugadores galardonados:* A lo largo de la temporada la LNB premia a los integrantes del quinteto ideal de la semana (durante las 28 semanas de temporada regular), así como también a los mejores quintetos de las distintas instancias de post-temporada. Por otro lado, al finalizar la temporada regular, se otorgan los principales premios individuales de desempeño (Jugador Más Valioso, Mejor Jugador Nacional, Mejor Jugador Extranjero, Mejor Defensor, Jugador Revelación, Sexto Hombre y Jugador de Mayor Progresión), donde para cada uno de estos premios se selecciona previamente una terna de tres jugadores. Dentro de esta ceremonia se premia también al quinteto ideal de toda la temporada.

En total, se identificaron 81 jugadores que recibieron al menos un galardón o que integraron alguna terna durante la temporada en estudio, de los cuales 14 obtuvieron alguno de los premios de mayor relevancia. Como medida de validación se calculó el porcentaje de jugadores ubicados en el top 50 de cada ranking RAPM que recibieron al menos un galardón o integraron alguna terna.

- *Criterio de jugadores con poco tiempo de juego:* Se identificaron los 50 jugadores con menor cantidad de minutos disputados durante la temporada y se calculó la proporción de ellos que aparecían entre los 50 mejores jugadores según cada ranking ofensivo y defensivo. Dado que la escasa participación suele generar estimaciones inestables, se espera que un

modelo con mejor desempeño ubique a una menor cantidad de estos jugadores en las primeras posiciones del ranking.

- *Criterio de jugadores titulares:* Se calculó la proporción de jugadores ubicados en el top 50 de cada ranking RAPM que formaban parte del grupo de titulares de sus respectivos equipos, definidos como los seis jugadores con mayor cantidad de minutos disputados durante la temporada.
- *Criterio del box score:* Se identificaron los 50 mejores jugadores según distintas estadísticas tradicionales del *box score*. Para la evaluación ofensiva se consideraron los puntos, las asistencias y los rebotes ofensivos, mientras que para la evaluación defensiva se utilizaron los rebotes defensivos, los recuperos y las tapas. Posteriormente, se calculó la proporción de coincidencia entre estos grupos de jugadores y el top 50 de los rankings ofensivos y defensivos, respectivamente.

5 Resultados

5.1 Análisis descriptivo

La temporada 2024/2025 de la Liga Nacional de Básquet contó con 20 equipos participantes, los cuales disputaron 38 partidos cada uno a lo largo de dicho año de competencia, a excepción de Zarate Basket (36 partidos), Instituto (37 partidos) y Riachuelo (37 partidos) que disputaron una menor cantidad debido a la suspensión de 2 partidos.

Del total de partidos analizados en este período, se identificaron 58625 posesiones finalizadas, obteniendo un promedio de 155,09 posesiones en promedio por partido (77,54 posesiones promedio por equipo).

5.1.1 Puntos por posesión

Cada una de las posesiones analizadas contabilizaba cierta cantidad de puntos al finalizar, presentandose un rango de puntos que varió de 0 a 7 puntos. Resultando los casos de 5,6 y 7 puntos situaciones extremadamente atípicas (0,089% de los casos). El resultado más frecuente al finalizar una posesión fue la ausencia de puntos, obteniendose en 31241 posesiones, lo cual representa un 53,2% del total de posesiones. Dicha información se ve reflejada en el Cuadro 5.

El promedio de puntos por posesión en la temporada fue de 1,04 pts.

Cuadro 5: Distribución de puntos por posesión

Puntos	Posesiones	%
0	31241	53.290
1	2385	4.068
2	16670	28.435
3	8134	13.875
4	143	0.244
5	45	0.077
6	6	0.010
7	1	0.002

5.1.2 Rendimiento de los equipos

Antes de analizar las métricas individuales, resulta conveniente presentar el desempeño general de los equipos durante la fase regular de la temporada 2024/2025. El Cuadro 6 muestra la tabla de posiciones final de la Liga Nacional, la cual servirá como referencia para interpretar los resultados obtenidos por las distintas métricas evaluadas en las secciones siguientes.

Cuadro 6: Tabla de posiciones de la Liga Nacional 2024/2025

Equipo	Pts	PJ	PG	PP	PF	PC	+/-	
Boca Juniors	67	38	29	9	3097	2884	213	1°.
Oberá	64	38	26	12	3140	2960	180	2°.
Instituto	64	38	26	12	3073	2790	283	3°.
Quimsa	63	38	25	13	3320	2973	347	4°.
Obras	62	38	24	14	3134	3028	106	5°.
Riachuelo	60	37	22	15	3032	2894	138	6°.
Regatas	58	38	20	18	3018	3015	3	7°.
Ferro	58	38	20	18	3108	3131	-23	8°.
Gimnasia	58	38	20	18	3141	2985	156	9°.
San Martín	57	38	19	19	2824	2779	45	10°.
Unión	57	38	19	19	3116	3237	-121	11°.
Atenas	57	38	19	19	2997	3058	-61	12°.
Peñarol	55	38	18	20	3085	2990	95	13°.
Olímpico	55	38	17	21	3067	3168	-101	14°.
San Lorenzo	55	38	17	21	2945	3034	-89	15°.
Platense	53	38	15	23	3018	3125	-107	16°.
Independiente	52	38	14	24	3237	3348	-111	17°.
La Unión	51	38	13	25	3199	3286	-87	18°.
Zárate	48	37	10	27	2723	3097	-374	19°.
Argentino	44	38	6	32	2724	3216	-492	20°.

5.1.3 Análisis de *plus-minus*

Como primera aproximación a la evaluación del rendimiento individual, se analizó la métrica *plus-minus* (+/-), la cual brinda un indicio de cuán eficiente fue el jugador en el tiempo que permaneció en cancha, calculando la diferencia de puntos realizados por el equipo propio en comparación con los puntos del rival dentro de ese intervalo de tiempo.

El Cuadro 7 deja en evidencia que los jugadores con mayor +/- pertenecen, en su mayoría,

a los equipos que mejores resultados obtuvieron durante la temporada regular. Donde nueve de los once jugadores mejor ubicados integraron alguno de los cuatro primeros equipos de la clasificación (Boca Juniors, Oberá Tenis Club, Instituto y Quimsa). Las únicas excepciones fueron Marcos Chacón Tirado y Diego Rafael Figueredo, quienes registraron valores elevados de *plus-minus* a pesar de formar parte de equipos ubicados en la mitad de la tabla de posiciones.

Cuadro 7: Jugadores con mayor plus-minus

jugador	Equipos	+/-
LOUIS, ARNOLD MICHAEL	QUIMSA	306
VILDOZA, LEANDRO	INSTITUTO	297
POMOLI LARRABURU, NICOLA	INSTITUTO	284
CUELLO, MARTIN NICOLAS	BOCA	254
COPELLO, NICOLAS	INSTITUTO	245
VORHEES, WILLIAM LEONARD-DEUBLER	OBERA	224
LUGARINI, BAUTISTA	INSTITUTO	211
VILDOZA, JOSE IGNACIO	BOCA	209
FIGUEREDO, DIEGO RAFAEL	RIACHUELO	205
BRUSSINO, JUAN IGNACIO	QUIMSA	201
CHACON TIRADO, MARCOS	GIMNASIA	201

En el extremo opuesto se observa un patrón aún más marcado. Durante la temporada, Zárate Basket y Argentino de Junín presentaron un rendimiento considerablemente inferior al resto de los equipos, situación que se tradujo en diferencias de puntos ampliamente negativas. Como consecuencia, los diez jugadores con menor +/- de la competencia pertenecieron exclusivamente a esos equipos, tal como se presenta en el Cuadro 8.

Cuadro 8: Jugadores con menor plus-minus

jugador	Equipos	+/-
GOMEZ, MANUEL ALEJANDRO	ARGENTINO	-409
SLIDER, JONATAN	ARGENTINO	-352
ALLENDE, TOMAS DANIEL	ARGENTINO	-295
FRONTERA, RAMIRO JEREMIAS	ARGENTINO	-264
PIÑERO, PATRICIO	ZARATE BASKET	-252
PODESTA, FERNANDO ARIEL	ARGENTINO	-251
HERNANDEZ, MANUEL ALONSO	ARGENTINO	-241
MERCHANT, EDGAR HENRY	ZARATE BASKET	-194
DIGGS, AVERY GERELL	ZARATE BASKET	-190
CAPPONI, FEBO LORENZO	ZARATE BASKET	-187

Queda evidenciado que los rendimientos propios de cada equipo dictan en gran medida quiénes lideran o cierran los rankings de *plus-minus*, reafirmando la dificultad que presenta esta medida tradicional para aislar el verdadero impacto individual del jugador respecto del contexto en el que participa.

5.1.4 Análisis del *plus-minus* por cada 100 posesiones

El *plus-minus* acumulado a lo largo de la temporada se encuentra muy influenciado por la cantidad de posesiones en las que participa cada jugador. Por ejemplo, dos jugadores con desempeños similares pertenecientes a un equipo con muy buen desempeño en general, pueden diferir en esta métrica en caso de que uno de ellos dispute una mayor cantidad de partidos o permanezca más tiempo en cancha.

Con el propósito de reducir inicialmente la influencia de este volumen de participación, se calculó el *plus-minus* por cada 100 posesiones:

$$PM_k^{100} = \frac{PM_k \cdot 100}{N_k}$$

donde PM_k representa el *plus-minus* acumulado del jugador k y N_k la cantidad de posesiones en las que participó.




Figura 10: Ranking de plus-minus ponderado por cantidad de posesiones

Al observar los resultados, los valores más extremos de la distribución se concentran entre los jugadores con menor participación. En particular, los 15 valores más altos y los 39 más bajos corresponden a jugadores que participaron en menos de 500 posesiones durante la temporada. Esta concentración en ambos extremos sugiere que, cuando se presentan pocas observaciones, la métrica resulta especialmente sensible a unas pocas acciones favorables o desfavorables y, por lo tanto, presenta una mayor variabilidad.

Para abordar este problema, manteniendo consistencia con el criterio adoptado posteriormente para el tratamiento de los jugadores con poca participación, se restringió el análisis a quienes disputaron al menos 500 posesiones en la temporada.

En el cuadro 9 se presentan los diez valores más altos y los diez más bajos del plus-minus por cada 100 posesiones bajo esta condición.

Cuadro 9: Jugadores con mayor plus-minus por cada 100 posesiones

jugador	Equipos	posesiones	+/-	PM^{100}
LOUIS, ARNOLD MICHAEL	QUIMSA	3052	306	10.0262
VILDOZA, LEANDRO	INSTITUTO	3302	297	8.9945
POMOLI LARRABURU, NICOLA	INSTITUTO	3243	284	8.7573
CHACON TIRADO, MARCOS	GIMNASIA	2326	201	8.6414
VASIRANI, EDUARDO MARTIN	QUIMSA	2383	182	7.6374
SANSIMONI, BRUNO	QUIMSA	2006	152	7.5773
RIVERO, CARLOS EZEQUIEL	GIMNASIA	1629	123	7.5506
COPELLO, NICOLAS	INSTITUTO	3366	245	7.2787
PIÑERO, FACUNDO	BOCA	2387	160	6.703
CUELLO, MARTIN NICOLAS	BOCA	3850	254	6.5974

Luego de aplicar esta restricción, dos jugadores de Gimnasia de Comodoro se ubican entre los diez valores más altos. Evidenciando un impacto positivo de estos jugadores en el tiempo que estuvieron en cancha, destacando en un equipo de mitad de tabla.

Cuadro 10: Jugadores con menor plus-minus por cada 100 posesiones

jugador	Equipos	posesiones	+/-	PM^{100}
ALONSO, GONZALO NICOLAS	LA UNION FSA.	541	-65	-12.0148
GOMEZ, MANUEL ALEJANDRO	ARGENTINO	3702	-409	-11.0481
ROVERES, AUGUSTO DANIEL	FERRO	511	-53	-10.3718
THORNTON, RAYNERE ZYNIQUE	ARGENTINO	1088	-108	-9.9265
SLIDER, JONATAN	ARGENTINO	3685	-352	-9.5522
MAXWELL, DU'VAUGHN ELISHA	OLIMPICO	611	-54	-8.838
ALLENDE, TOMAS DANIEL	ARGENTINO	3344	-295	-8.8218
CAPPONI, FEBO LORENZO	ZARATE BASKET	2179	-187	-8.5819
PODESTA, FERNANDO ARIEL	ARGENTINO	3047	-251	-8.2376
ROMERO, GONZALO EMMANUEL	ARGENTINO	587	-48	-8.1772

Mientras que en la parte inferior (Cuadro 10) la composición del ranking deja de concentrarse exclusivamente en jugadores de Argentino de Junín y Zárate Basket, e incorpora también jugadores de La Unión de Formosa, Ferro y Olímpico.

De igual manera, esta normalización de la métrica tradicional no elimina todas limitaciones del *plus-minus*, dado que la métrica continúa sin considerar la calidad de los compañeros y rivales con los que cada jugador compartió cancha.

5.1.5 Análisis del *plus-minus* estandarizado por equipo

Como ya se mencionó, el cálculo de $+/-$ por posesión resulta muy informativo, pero lo es más si se piensa dentro del contexto del equipo. Tal como se evidencia en la Figura 13, los valores presentados en dicha métrica dependen fuertemente del desempeño de cada equipo, donde equipos clasificados a *playoffs* presentan jugadores con valoración generalmente positiva y equipos ubicados en el fondo de la tabla presentan, en su mayoría, una valoración negativa.




Figura 11: plus-minus cada 100 posesiones por equipo

Pensando en mitigar el efecto, tanto positivo como negativo, que genera pertenecer a cierto equipo, se evalúa el $+/-$ por 100 posesiones en relación a los valores de dicha métrica presentados por los propios compañeros del equipo. De esta forma, se busca identificar a aquellos jugadores

que, aun perteneciendo a un equipo con una diferencia de anotación desfavorable, presentan un desempeño relativo superior al de sus compañeros.

Para ello se utilizó una estandarización robusta, basada en la mediana y la desviación absoluta mediana (*median absolute deviation*, MAD), en lugar de la media y la desviación estándar. Para un jugador k perteneciente al equipo e , se definió:

$$PM_k^{est} = \frac{PM_k^{100} - \widetilde{PM_e^{100}}}{MAD_e(PM^{100})}$$

Valores positivos indican que el jugador registró un +/- por 100 posesiones superior a la mediana de sus compañeros, mientras que los valores negativos señalan un desempeño inferior en términos relativos dentro de su equipo.

Cuadro 11: Jugadores con mayor plus-minus estandarizado

jugador	Equipos	Posesiones	+/-	+/- estandarizado
SANDERS, NAKIE GERALD	ATENAS	1211	60	5.5182
GARELLO, VICENTE	SAN MARTIN	1524	95	3.6429
MAINOLDI, LEONARDO ANDRES	OLIMPICO	595	41	3.0983
CHACON TIRADO, MARCOS	GIMNASIA	2326	201	2.8492
HARINA MARTINI, FEDERICO GABRIEL	LA UNION FSA.	2982	55	2.3924
RIVERO, CARLOS EZEQUIEL	GIMNASIA	1629	123	2.3861
CAPELLI, SANTIAGO	ARGENTINO	554	-16	2.2476
CARABALI POROZO, BRYAN JOSE	SAN MARTIN	790	33	2.156
LOUIS, ARNOLD MICHAEL	QUIMSA	3052	306	2.0007
DATO, MARTINIANO	GIMNASIA	2653	173	1.949

En el cuadro 11 se observa que los tres primeros puestos corresponden a jugadores que no disputaron la temporada completa con sus respectivos equipos. Nakye Sanders y Garelo Vicente se incorporaron como refuerzos a Atenas y San Martín, respectivamente, mientras que Leonardo Mainoldi dejó Olímpico luego de los primeros siete encuentros.

En los tres casos, su participación coincide con períodos de mejores resultados para sus equipos. Atenas registró un récord de 9 victorias y 9 derrotas con Sanders, frente a 9-11 en los partidos

que disputó sin él. Por su parte, San Martín obtuvo un récord de 4-10 antes de la llegada de Garelo Vicente y de 15-9 desde su incorporación. Finalmente, Olímpico inició la temporada con un registro de 5-2 mientras contó con Mainoldi, pero acumuló 12 triunfos y 19 derrotas tras su partida. Si bien estas diferencias no permiten atribuir causalmente los cambios en el rendimiento colectivo a un único jugador, aportan contexto coherente con las elevadas valoraciones relativas que presentan dentro de sus planteles.

Asimismo, entre los puestos superiores aparece Santiago Capelli, a pesar de registrar un +/- negativo en términos absolutos. Su caso ilustra el propósito de la estandarización: aunque integró Argentino de Junín, el equipo con peor desempeño de la temporada, su diferencial fue considerablemente más favorable que el de sus compañeros.

Cuadro 12: Jugadores con peor plus-minus estandarizado

jugador	Equipos	Posesiones	+/-	+/- estandarizado
ALONSO, GONZALO NICOLAS	LA UNION FSA.	541	-65	-6.2205
PAYTON CLOTTEY, EMMANUEL TRAVON	SAN MARTIN	966	-63	-5.5804
DIGON, ALEJO ADRIEL	OBRAS	691	-33	-4.7101
ROVERES, AUGUSTO DANIEL	FERRO	511	-53	-4.0184
LEDESMA, RAMIRO	ATENAS	1484	-75	-3.6748
MAXWELL, DU'VAUGHN ELISHA	OLIMPICO	611	-54	-2.7516
MITCHELL JR, TONY RASEAN	UNION	690	-55	-2.6258
KRAYEM, OMAR NABIL	RIACHUELO	551	-35	-2.5965
JARA, CESAR AGUSTIN	INDEPENDIENTE	3016	-175	-2.4791
ROMANO, NICOLAS	QUIMSA	2186	28	-2.4588

De manera similar, entre los puestos inferiores del ranking aparece Nicolas Romano, presentando un +/- positivo en términos absolutos. Integró al equipo con mayor +/- a lo largo de la temporada, pero presentó un desempeño muy por debajo al de sus compañeros.

Esta medida complementa el análisis del +/- por 100 posesiones al identificar la posición relativa de cada jugador dentro de su plantel. Sin embargo, los valores deben interpretarse principalmente como una medida del desempeño de cada jugador respecto al de sus compañeros, y no como una medida directa de rendimiento individual aislada del contexto del equipo.

5.2 Métricas basadas en modelos estadísticos

Las métricas descriptivas analizadas previamente permiten caracterizar el rendimiento observado mientras cada jugador permaneció en cancha. Sin embargo, no controlan simultáneamente la calidad de sus compañeros y rivales. Los modelos RAPM intentan aislar estadísticamente estas contribuciones mediante variables indicadoras que representan a los jugadores presentes en cada posesión.(ver)

5.2.1 RAPM

Como primer medida estandar a evaluar, se planteó un modelo de regresión lineal múltiple normal. Para el cual se consideraron $K = 229$ jugadores (66,1% del total) que superaron el filtro de cantidad de posesiones, derivando en 458 indicadores de presencia, 229 ofensivos y 229 defensivos. Los coeficientes se estimaron mediante *Ridge*, *Lasso* y *Elastic Net* para reducir la inestabilidad generada por la multicolinealidad y la escasa cantidad de observaciones de algunos jugadores.

Dichas técnicas requirieron realizar una selección de los hiperparámetros que controlan la magnitud de las penalizaciones realizadas. *Ridge* y *Lasso* requieren seleccionar λ , mientras que *Elastic Net* requiere seleccionar conjuntamente α y λ . Para esto se utilizó validación cruzada de diez particiones y se eligieron los valores que minimizaban el error cuadrático medio.

Los resultados obtenidos se presentan en el Cuadro 13.

Cuadro 13: Técnicas de regularización y valores de hiperparámetros.

Penalización	α	λ	CME CV	Coeficientes activos
Ridge	0	0,06258	1,405088	458
Lasso	1	0,00085	1,405401	98
Elastic Net	0,005	0,04261	1,405031	331

Las distintas regularizaciones presentaron medidas de error muy similares, siendo *Elastic Net* la mejor entre las tres alternativas. También se observan valores absolutos bajos para los coeficientes de penalización, lo cual no debe confundirse con una baja penalización, ya que

para el caso de *LASSO* se redujo el 78,60% de los coeficientes a 0. Mientras que en el caso de *Elastic Net* donde se presentó una penalización aparentemente dominada por L_2 ($\alpha = 0,005$), también se anularon un 27,72% de los coeficientes.

Llevando esta perspectiva sobre los jugadores, de los 229 jugadores que ingresaron en el modelo, 144 presentaron ambos coeficientes iguales a 0 en el modelos *LASSO*, mientras que solo 22 cumplieron esa condición con *Elastic Net*. En estos casos, la anulación de un coeficiente no implica necesariamente que un jugador carezca de impacto, sino que, a partir de la información aportada por el resto de los predictores, su efecto ofensivo o defensivo no resultó suficientemente distinguible del grupo de referencia. Esta anulación puede estar asociada tanto con la cantidad de posesiones disputadas como con la elevada correlación existente entre jugadores que comparten frecuentemente sus minutos en cancha.

Por otro lado, el modelo *Ridge* no reduce los coeficientes exactamente hasta 0, pero sí los penaliza. 51 coeficientes presentaron una magnitud inferior a 0,001 puntos por posesión, equivalente a un efecto inferior a 0,1 puntos cada 100 posesiones.




Figura 12: Distribución de RAPMs según regularización

La Figura 14 presenta la distribución de los coeficientes activos luego de la regularización. *Ridge* conservó la totalidad de los parámetros, pero también concentró una proporción alta de ellos alrededor de cero. En cambio, *LASSO* conservó un conjunto reducido de efectos, aunque generalmente de mayor magnitud. *Elastic Net* presentó un comportamiento intermedio, al anular el 27,7 % de los parámetros y mantener una distribución más próxima a la obtenida mediante *Ridge*.

Debe considerarse que estos modelos normales representan los puntos por posesión mediante una variable continua, pese a su naturaleza discreta y a la elevada concentración de observaciones con cero puntos. Por este motivo, a continuación se presentan los resultados obtenidos mediante regresión logística multinomial y las métricas EPTS derivadas de sus probabilidades estimadas.

5.2.2 EPTS

Se procede a la implementación de los modelos de regresión logística multinomial para modelar la probabilidad estimada de cada tipo de anotación. Siguiendo la metodología propuesta con los modelos normales, los coeficientes de estos modelos serán obtenidos a través de distintas técnicas de regularización. Solo que para estos modelos la medida de error a minimizar fue la *Deviance*.

Se decidió utilizar el parámetro `type.multinomial = "grouped"`, el cual aplica una penalización grupal: los coeficientes de un mismo predictor en las distintas categorías de respuesta se tratan como un grupo. De esta manera, el efecto ofensivo o defensivo de un jugador permanece activo o es anulado simultáneamente para todos los tipos de anotación.

Cuadro 14: Técnicas de regularización y valores de hiperparámetros.

Penalización	α	λ	<i>Deviance</i> CV	Predictores activos
Ridge	0	0,00946	2,195519	458
Lasso	1	0,00039	2,196606	199
Elastic Net	0,005	0,00562	2,195772	457

La menor *Deviance* de validación cruzada se obtuvo mediante *Ridge*. Además se observó un incremento en esta métrica a medida que aumentó el valor de α , lo que indica que, para estos datos, la componente L_2 de la penalización resultó más adecuada que la selección de coeficientes generada por L_1 . El mejor modelo *Elastic Net* (por fuera de $\alpha = 0$) correspondió a $\alpha=0,005$, con una *Deviance* levemente superior a la obtenida mediante *Ridge*. A pesar de presentar peores valores de la métrica de validación, se conservó como representante de *Elastic Net* para comparar el comportamiento de las distintas técnicas de regularización. Finalmente, *LASSO* presentó la mayor *Deviance* comparado con el resto, aunque es importante resaltar que estas diferencias son mínimas.

Al analizar la reducción de coeficientes de los distintos modelos, se observa que el modelo *Elastic Net* seleccionado solo anuló un predictor defensivo, debido al reducido peso asignado a la componente L_1 . Mientras que el modelo *LASSO* redujo 259 coeficientes a 0, de los cuales se

desprende que 82 jugadores tienen los 2 coeficientes nulos, 49 solo el coeficiente ofensivo nulo y 46 solo el defensivo nulo.

Estos modelos permiten cuantificar el aporte de los jugadores a cada uno de los distintos tipos de anotación, midiendo su contribución tanto ofensiva como defensiva en cada caso. Pero en base al objetivo de esta tesina, se buscará unificar este aporte en un único índice de rendimiento. Obteniendo así la métrica denominada: *Expected Points* (EPTS).




Figura 13: Distribución de EPTS ofensivos y defensivos según regularización

Al analizar las métricas ofensivas y defensivas generadas por cada modelo, se puede identificar una similitud muy marcada entre los resultados provistos por *Ridge* y *Elastic Net* (Figura 15). Para evaluar específicamente la concordancia entre sus rankings, se calculó el coeficiente de correlación de Spearman, obteniéndose valores de 0,9988 para el componente ofensivo y 0,9987 para el defensivo. Estos resultados indican que ambos modelos producen ordenamientos prácticamente idénticos. Estos resultados son coherentes con el bajo valor de α seleccionado

para *Elastic Net* ($\alpha = 0,005$), por lo cual se confirma que la penalización L_2 es la predominante. Mientras que para *LASSO* se observa que, al igual que en los modelos normales, la distribución de las métricas es más dispersa, con colas más pronunciadas. Debido en gran medida a la cantidad de coeficientes reducidos a 0 en la regularización.

5.2.3 wEPTS

Una vez obtenidos los EPTS se calcula su versión ponderada según la proporción de posesiones de su equipo en las que participó cada jugador. Este índice actúa como un *shrinkage* sobre el EPTS penalizando a los jugadores con menos tiempo de juego, contrayendo sus EPTS hacia los puntos esperados del grupo de referencia. En caso de que el jugador si participara en todas las posesiones de su equipo, el wEPTS sería igual al EPTS.

Para evidenciar el efecto de esta ponderación, se compararon las distribuciones de EPTS y wEPTS obtenidas mediante *Ridge*.




Figura 14: Comparación de distribuciones: EPTS vs wEPTS

A través de la Figura 16 se observa que las mayores reducciones absolutas no se concentran necesariamente entre quienes presentan muy baja participación durante la temporada. Cuatro de los cinco jugadores mejor ubicados en el ranking ofensivo de EPTS se encontraron entre los más afectados por la ponderación, a pesar de haber participado aproximadamente en el 40%–45% de las posesiones de sus equipos. Como consecuencia, registraron caídas relevantes en el ranking:

- MORRISON, DOMINIQUE MONTEL pasó del 1er puesto en el ranking de EPTS al 3ro en el de wEPTS.
- CHACON TIRADO, MARCOS pasó del 3er puesto al 15vo, recibiendo la mayor penalización entre las métricas ofensivas (una diferencia de -0,02118 puntos esperados).

- DATO, MARTINIANO pasó del 4to puesto al 9no en el ranking wEPTS.
- THOMAS III, CHARLES PRICE pasó del 5to puesto al 12vo.

Por otra parte, al analizar las métricas defensivas presentadas en la Figura 17 también se observa un comportamiento similar al mencionado.




Figura 15: Comparación de distribuciones: EPTS vs wEPTS

Donde destaca **SANDERS**, **NAKIE GERALD**, jugador que presentó la mayor reducción en la métrica entre todos los predictores (diferencia de 0,02215). Pasando del 9no puesto defensivo en el ranking EPTS al 39° en el ranking wEPTS.

Entre los cinco jugadores con mayor penalización en su métrica defensiva encontramos, al igual que sucedió con la métrica ofensiva, al jugador **CHACON TIRADO**, **MARCOS**, el cual pasó del 7mo

puesto defensivo al 13vo en el nuevo ranking. Identificandose como uno de los jugadores más afectados por esta nueva métrica ponderada.

Vemos que los jugadores más afectados en términos absolutos son los que están en las primeras posiciones de los rankingg, esto se debe a que... Este resultado se explica porque la magnitud absoluta del ajuste depende conjuntamente de la participación y de la distancia entre el EPTS original y el valor de referencia. Por definición:

$$wEPTS_k - EPTS_0 = W_k(EPTS_k - EPTS_0)$$

Por lo tanto, luego de aplicar la ponderación, el jugador conserva una proporción de W_k de su distancia original respecto de $EPTS_0$. De esta manera, quienes tienen menor participación siempre van a presentar una contracción proporcional mayor. Sin embargo, el cambio absoluto es:

$$|wEPTS_k - EPTS_k| = (1 - W_k)|EPTS_k - EPTS_0|$$

Por eso, un jugador con una participación intermedia (como la gran mayoría de casos que se vieron anteriormente) puede ser uno de los más afectados en términos absolutos si su EPTS original está muy alejado de $EPTS_0$.

En conclusión, wEPTS no solo estabiliza las estimaciones de jugadores con escasa presencia, sino que modifica la interpretación del ranking. Esto se debe a que las dos medidas parecieran responder a problemas diferentes, wEPTS puede interpretarse como una medida de contribución total del rendimiento de los jugadores a lo largo de toda la temporada, mientras que EPTS describe principalmente el rendimiento esperado durante las posesiones en las que el jugador se encuentra en cancha.

5.3 Comparación de modelos

5.3.1 Bondad de ajuste

La capacidad predictiva de estos modelos se compara, al igual que en el artículo de referencia, mediante el RMSE. Las predicciones de cada posesión utilizadas para obtener esta medida fueron obtenidas mediante un reajuste de los modelos, donde en cada caso se fue excluyendo sucesivamente uno de los *folds*, se entrenó el modelo con los nueve restantes y se predijeron las posesiones pertenecientes al *fold* omitido.

Los resultados fueron los siguientes:

Cuadro 15: RMSE out-of-fold para cada modelo

Modelo	RMSE
Normal Ridge	1.185367
Normal LASSO	1.185494
Normal Elastic Net	1.185344
Multinomial Ridge	1.185414
Multinomial LASSO	1.185505
Multinomial Elastic Net	1.185378

En base al Cuadro 15 se puede notar que ninguna combinación de distribución y regularización pareciera producir una mejora predictiva importante sobre las demás. Siendo la mejor métrica obtenida por el modelo de regresión múltiple penalizada con *Elastic Net*, con un $RMSE = 1,185344$; sin embargo, la diferencia respecto del modelo multinomial *LASSO*, que presentó el valor más elevado, fue de apenas 0,000161.

Dado que el RMSE evalúa únicamente la precisión del valor esperado de puntos, se complementó este análisis mediante el otro procedimiento propuesto por Damoulaki et al. (2025), comparando la distribución empírica de los puntos por posesión con la obtenida a partir de simulaciones del modelo multinomial.




Figura 16: Simulación de distribución empírica

Para cada categoría de anotación se representó la distribución de las proporciones obtenidas en 1.000 simulaciones. Como se observa en la figura 18, las distribuciones se concentraron alrededor del valor empírico y fueron prácticamente iguales entre las tres técnicas de regularización, lo que indica que los modelos multinomiales reproducen de manera adecuada, y similar entre sí, la distribución marginal observada de los puntos por posesión.


5.3.2 Consistencia

Los resultados anteriores mostraron que las distintas combinaciones de distribución y técnica de regularización presentaron una capacidad predictiva prácticamente equivalente. Sin embargo, una bondad de ajuste similar no implica necesariamente que los rankings estimados sean igualmente confiables. Un modelo puede reproducir adecuadamente los resultados observados y, al mismo tiempo, generar métricas muy sensibles a los partidos incluidos en el conjunto de

datos.

Siguiendo el enfoque propuesto por Hvattum, se evaluó entonces la consistencia de los modelos, entendida como su capacidad para producir valoraciones similares al ser ajustados sobre muestras diferentes. Para ello, los partidos fueron distribuidos aleatoriamente en dos particiones con cantidades similares de posesiones, manteniendo todas las posesiones de un mismo encuentro dentro de una única partición. Posteriormente, cada modelo fue reajustado de manera independiente y se calculó la correlación de Pearson entre los ratings obtenidos para los jugadores presentes en ambas muestras.

El análisis se realizó separadamente para las contribuciones ofensivas y defensivas. Como referencia adicional, las correlaciones observadas se compararon con rankings generados aleatoriamente para evidenciar mejoras sobre un escenario base.



Los segmentos grises representan el intervalo central del 95% de las correlaciones obtenidas al permutar los jugadores.

Figura 17: Análisis de consistencia de los rankings

Las correlaciones de Pearson obtenidas entre los rankings estimados en ambas particiones fueron

positivas en todas las combinaciones analizadas, aunque con asociaciones bajas a moderadas. Los valores variaron en un rango de 0,116 a 0,345, evidenciando cierta sensibilidad en los modelos, más aún si se utiliza solo media temporada para su cálculo.

Además, de este análisis se despenden los siguientes resultados:

- En términos generales, las contribuciones defensivas presentaron una mayor consistencia que las ofensivas. Los valores más elevados correspondieron al wEPTS defensivo estimado mediante Elastic Net y Ridge, con correlaciones de 0,345 y 0,337, respectivamente.
- *Elastic Net* presentó la mayor correlación en cinco de las seis combinaciones, aunque sus resultados fueron muy similares a los obtenidos mediante *Ridge*. En cambio, LASSO registró sistemáticamente las correlaciones de Pearson más bajas, llegando en algunos casos a valores que no pudieron distinguirse de los esperables bajo rankings aleatorios.
- 16 de las 18 combinaciones analizadas presentaron correlaciones mayores al percentil 97,5 de la distribución de las 5.000 correlaciones generadas mediante rankings aleatorios.
- Los dos rankings que parecieran haber sido más consistentes son: wEPTS - Ridge y wEPTS - Elastic Net.

5.3.3 Validación externa

Las evaluaciones anteriores permitieron analizar la capacidad de ajuste de los modelos y la estabilidad de las valoraciones obtenidas ante cambios en la muestra utilizada. Sin embargo, resulta importante complementar estos criterios con validaciones externas que permitan determinar en qué medida los rankings representan adecuadamente el rendimiento de los jugadores, o la percepción del rendimiento que los especialistas tienen sobre los mismos.

En un primer paso vamos a comparar las métricas con los primeros tres criterios mencionados en el apartado metodológico:

Cuadro 16: Comparación de rankings según criterios de validación externa

Modelo	Criterio 1 (%)	Criterio 2 (%)	Criterio 3a (%)	Criterio 3b (%)
RAPM - Ridge	49.4	6.0	66.0	59.0
RAPM - Lasso	43.2	13.0	61.0	57.0
RAPM - Elastic Net	50.6	6.0	65.0	59.0
EPTS - Ridge	49.4	12.0	61.0	54.0
EPTS - Lasso	54.3	5.0	67.0	64.0
EPTS - Elastic Net	49.4	11.0	61.0	55.0
wEPTS - Ridge	53.1	2.0	78.0	73.0
wEPTS - Lasso	54.3	5.0	68.0	63.0
wEPTS - Elastic Net	53.1	2.0	77.0	72.0

Los porcentajes se calcularon sobre 100 posiciones: las 50 primeras o últimas de los rankings ofensivos y las 50 primeras o últimas de los rankings defensivos. Criterio 1: jugadores galardonados incluidos en el top 100. Criterio 2: jugadores con menor participación incluidos en el top 100. Criterio 3a: titulares incluidos en el top 100. Criterio 3b: titulares incluidos en el bottom 100.

Al analizar el Cuadro 16, puede identificarse que los criterios basados en el tiempo de juego de los jugadores mejor calificados presentan mejores desempeños en las métricas wEPTS, de manera lógica debido a su formulación. Dentro de estas medidas, la que se destacó por sobre las demás fue la producida mediante regularización *Ridge*. Por otro lado, al observar la proporción de jugadores premiados a lo largo de la temporada en las posiciones altas de los rankings, los desempeños fueron más similares, siendo el modelo multinomial estimado mediante *LASSO* el que produzco el mejor resultado, alcanzando a un 54,3 de los galardonados tanto en los rankings EPTS como en los wEPTS.

Cuadro 17: Comparación de los rankings según estadísticas tradicionales del box score

Modelo	Estadísticas ofensivas			Estadísticas defensivas		
	PTS (%)	AST (%)	OREB (%)	DREB (%)	STL (%)	BLK (%)
RAPM - Ridge	40.0	34.0	34.0	22.0	30.0	26.0
RAPM - Lasso	36.0	30.0	30.0	30.0	30.0	30.0
RAPM - Elastic Net	40.0	34.0	34.0	22.0	30.0	26.0
EPTS - Ridge	36.0	26.0	34.0	22.0	28.0	30.0
EPTS - Lasso	44.0	28.0	32.0	26.0	36.0	24.0
EPTS - Elastic Net	38.0	28.0	36.0	22.0	28.0	30.0
wEPTS - Ridge	48.0	38.0	42.0	32.0	36.0	28.0
wEPTS - Lasso	44.0	28.0	32.0	26.0	36.0	24.0
wEPTS - Elastic Net	48.0	40.0	40.0	30.0	36.0	28.0

PTS: puntos totales; AST: asistencias totales; OREB: rebotes ofensivos totales; DREB: rebotes defensivos totales; STL: recuperos totales; BLK: tapas totales.

Analizando las estadísticas del *box score*, vuelven a encontrarse mejores resultados en los modelos wEPTS estimados mediante *Elastic Net* y *Ridge*, especialmente al realizar comparaciones a través de las estadísticas ofensivas, donde dichas métricas dominan en todos los casos. En las variables defensivas no se observó un modelo claramente dominante. Los rankings wEPTS estimados mediante *Ridge* y *Elastic Net* alcanzaron la mayor coincidencia en rebotes defensivos (32%), mientras que los mayores porcentajes en recuperos y tapas correspondieron a distintas variantes de RAPM.

En términos generales, las coincidencias fueron superiores para las estadísticas ofensivas: el promedio entre modelos fue de 36,1%, frente al 22,3% registrado en las defensivas. Este patrón coincide con lo señalado por Damoulaki et al. (2025), donde se sostiene que el rendimiento ofensivo puede asociarse más con la habilidad individual de los jugadores, mientras que el éxito defensivo depende en mayor medida de la coordinación y cooperación colectiva. Sin embargo, se considera que el planteo realizado por Damoulaki resulta parcial o incompleto, debido a

que la menor coincidencia observada no debe atribuirse exclusivamente a una limitación de los modelos, sino a una limitación propia de las medidas tradicionales defensivas como los rebotes defensivos, los recuperos y las tapas las cuales no cuantifican de manera adecuada el aporte defensivo defensivo del jugador y no capturan aspectos importantes como el posicionamiento, las rotaciones o la intensidad.

Adicionalmente, se incorporaron comparaciones con los rankings generados mediante las métricas descriptivas basadas en el *plus-minus*, lo que permite evaluar si los modelos propuestos generan valoraciones similares con otras medidas que buscan explicar el mismo fenómeno. Los resultados obtenidos se presentan en el Cuadro 18.

Cuadro 18: Concordancia entre los rankings estimados y las medidas descriptivas basadas en plus-minus

Modelo	Puntos realizados		Puntos recibidos	
	Por posesión (%)	Estandarizados (%)	Por posesión (%)	Estandarizados (%)
RAPM - Ridge	86	58	76	66
RAPM - Lasso	48	48	54	50
RAPM - Elastic Net	84	58	78	66
EPTS - Ridge	78	58	66	72
EPTS - Lasso	62	56	60	58
EPTS - Elastic Net	78	60	66	70
wEPTS - Ridge	72	54	60	58
wEPTS - Lasso	60	56	60	58
wEPTS - Elastic Net	74	52	62	58

Cada celda indica el porcentaje de jugadores del top 50 del ranking estimado que también pertenece al top 50 de la correspondiente medida descriptiva.

Los rankings estimados mediante *Ridge* y *Elastic Net* mostraron una mayor concordancia con las medidas basadas en *plus-minus* en comparación con los rankings producidos mediante *LASSO*. Este menor grado de coincidencia podría relacionarse con la mayor contracción ejercida por *LASSO*, que lleva a cero una proporción considerable de los coeficientes. Por otro lado, los

rankings RAPM tendieron a presentar una mayor concordancia que los derivados de los modelos multinomiales, particularmente en las medidas por posesión. Sin embargo, este resultado debe interpretarse con cautela, dado que el RAPM utiliza como variable respuesta los puntos anotados en cada posesión y, por lo tanto, su asociación con estas medidas descriptivas no constituye una validación completamente independiente

6 Conclusiones

...

7 Discusión

Los modelos RAPM utilizados en este trabajo, al igual que la literatura previa (Rosenbaum, 2004; Sill, 2010; Damoulaki et al., 2025), consideran cada posesión como una observación independiente. Sin embargo, esta hipótesis puede resultar discutible, dado que las posesiones pertenecientes a un mismo partido presentan dependencia temporal derivada de factores como el ritmo de juego, los ajustes tácticos, la fatiga y el contexto competitivo. Aunque esta dependencia no necesariamente sesga las estimaciones de los coeficientes bajo la hipótesis de exogeneidad de los errores, sí podría afectar su eficiencia y la correcta cuantificación de la incertidumbre. El desarrollo de modelos RAPM que incorporen explícitamente la correlación intra-partido constituye una línea de investigación aún poco explorada.

INTERPRETACIÓN Y COMPARACIÓN DE MODELOS DE REGRESIÓN LOGÍSTICA PARA EL ESTUDIO DE LA DESOCUPACIÓN (regresión logística con correlación, aplicación de modelos gee)

comparar lo escrito en este rmd con el que escribi para el anteproyecto, quizás este era una versión anterior y le faltan correcciones

evaluación de modelos de regresión lineal múltiple

El punto de corte utilizado para definir a los LTPs estuvo basado en el criterio que utilizó Damoulaki en su artículo, pero no deja de ser algo “arbitrario”. Podría analizarse distintos escenarios, con distintos puntos de corte y evaluar los resultados de cada modelo.

Ponderar los distintos momentos del partido de diferente manera (más peso a las situaciones clutch y menos a los garbage minutes), estaría bueno citar a algún artículo que haya realizado esto

Utilizar datos de varias temporadas dando más peso a las temporadas más actuales

Una de las motivaciones para desarrollar métricas RAPM consiste en superar este reduccionismo del box score y estimar contribuciones que no quedan registradas en las estadísticas individuales. Por lo tanto, una menor concordancia con estas medidas no debería interpretarse automáticamente como evidencia de menor validez del modelo, sino como una posible divergencia entre distintas formas de conceptualizar y medir el aporte defensivo.

8 Bibliografía

- Agresti, A. (2013). *Categorical Data Analysis* (3rd ed.). Wiley Series in Probability and Statistics. Wiley, New York.
- Damoulaki, A., Ntzoufras, I. & Pelechrinis, K. (2025). *Lasso multinomial performance indicators for in-play basketball data*. Comput Stat 40, 2157–2181.
- Dunn, P. K., & Smyth, G. K. (2018). *Generalized linear models with examples in R*. Springer.
- Gong, H., & Chen, S. (2024). *Estimating positional plus-minus in the NBA*. Journal of Quantitative Analysis in Sports.
- Hoerl, A. E., & Kennard, R. W. (1970). *Ridge regression: Biased estimation for nonorthogonal problems*. Technometrics, 12(1), 55–67.
- Hvattum, L. M. (2019). *A comprehensive review of plus-minus ratings for evaluating individual players in team sports*. International Journal of Computer Science in Sport, 18, 1–23.
- Ilardi, S. (2007). *Adjusted Plus-Minus: An idea whose time has come*. Blog: 82games. <http://www.82games.com/ilardi1.htm>
- Ilardi, S., & Barzilai, A. (2008). *Adjusted Plus-Minus ratings: New and improved for 2007–2008*. Blog: 82games. <http://www.82games.com/ilardi2.htm>
- James, G., Witten, D., Hastie, T., & Tibshirani, R. (2021). *An Introduction to Statistical Learning with Applications in R* (ISLR2).
- Kubatko, J., Oliver, D., Pelton, K., & Rosenbaum, D. (2007). *A starting point for analyzing basketball statistics*. Journal of Quantitative Analysis in Sports, 3, Article 1.
- Rosenbaum, D. (2004). *Measuring how NBA players help their teams win*. Blog: 82games. <http://www.82games.com/comm30.htm>
- Sæbø, O., & Hvattum, L. (2019). *Modelling the financial contribution of soccer players to their clubs*. Journal of Sports Analytics, 5, 23–34.

Sill, J. (2010). *Improved NBA adjusted +/- using regularization and out-of-sample testing*. Proceedings of the 2010 MIT Sloan Sports Analytics Conference.

Tibshirani, R. (1996). *Regression shrinkage and selection via the lasso*. Journal of the Royal Statistical Society: Series B (Methodological), 58(1), 267–288.

Yuan, M., & Lin, Y. (2006). *Model selection and estimation in regression with grouped variables*. Journal of the Royal Statistical Society: Series B, 68(1), 49–67.

Zou, H., & Hastie, T. (2005). *Regularization and Variable Selection via the Elastic Net*. Journal of the Royal Statistical Society: Series B, 67(2), 301–320.

9 Anexo

9.1 Controles de consistencia y corrección de errores en la base de datos

Durante el proceso de generación y preprocesamiento de la base de datos se implementaron distintos controles de consistencia con el objetivo de detectar posibles errores en la información obtenida mediante *web scraping*. Debido a que los registros del *play-by-play* son cargados manualmente por las mesas de control durante el desarrollo de los partidos, la fuente original puede presentar inconsistencias que requieren ser identificadas y, cuando resulte posible, corregidas antes de su utilización.

Para detectar posibles errores en la conformación de los quintetos en cancha, se construyó una variable que contabiliza la cantidad de jugadores presentes en cada quinteto para cada una de las acciones del partido. Dicha variable debería contabilizar un valor menor o igual a cinco para ambos equipos en todas las acciones registradas.

De esta manera se detectó un caso puntual en el partido de ZARATE BASKET vs ATENAS (C), donde el quinteto local registraba seis jugadores en cancha. Esta inconsistencia se observó

desde el inicio del segundo cuarto, con 10:00 minutos restantes, hasta el minuto 4:42 del mismo período.

Para subsanar este inconveniente, se realizó una revisión manual del *play-by-play* original disponible en la página web y se pudo identificar que al comienzo del segundo cuarto se había registrado incorrectamente el ingreso de seis jugadores en lugar de cinco, lo cual constituye un error atribuible a la mesa de control. Una vez identificada esta problemática, se revisó el contexto de las siguientes jugadas y pudo determinarse que el jugador MERCHANT, EDGAR HENRY no se encontraba realmente en cancha durante ese tramo del partido.

En consecuencia, se procedió a corregir el error eliminando al jugador mencionado de la variable correspondiente al quinteto local en las acciones afectadas, así como ajustando el conteo de jugadores en cancha. De esta manera, se restauró la consistencia lógica de los quintetos y se garantizó la validez de la información utilizada en las etapas posteriores del análisis.

9.2 Detección de errores en el marcador parcial: caso *QUIMSA vs BOCA (019/10/2024 11:30)*

Al revisar uno de los partidos con presencia de puntos incompatibles, se detectó que en el minuto 02:27 del tercer cuarto, el marcador parcial reflejaba correctamente el resultado del partido (64 - 42 a favor de QUIMSA). Sin embargo, la acción de anotación siguiente, el TIRO LIBRE ANOTADO del jugador de BOCA, PIÑERO, FACUNDO, en el minuto 02:21 del tercer cuarto, registraba un marcador parcial erróneo, de 67 - 43. Se observa entonces que el marcador parcial aumentó en tres puntos para el equipo local (QUIMSA) entre una acción y la siguiente, sin que existiera ninguna anotación registrada en el *play-by-play* que justificara dicha variación (Figura 8).




Figura 18: Comienzo de secuencia de acciones con errores en la carga del marcador

Estos errores siguieron presentandose en las siguientes acciones de anotación hasta el minuto 00:40, donde, con el TRIPLE del jugador de BOCA, CUELLO, MARTIN NICOLAS, el marcador parcial se reestablece a su valor real en ese momento (70 - 50), esta secuencia queda reflejada en la Figura 9.




Figura 19: Fin de secuencia de acciones con errores en la carga del marcador

Al presentarse errores en el marcador parcial de cada uno de los equipos, los puntos por posesión calculados como la diferencia del marcador de cada equipo con respecto al marcador parcial de la posesión anterior también eran erróneos.