

Métrica RAPM: Evaluación del impacto ofensivo y defensivo de los jugadores de la Liga Nacional de Básquetbol en Argentina

Tesina de grado

Estudiante: Simón Pedro Gazze

Director: Andrés Sosa

Co-directora: Cristina Cuesta

Fecha: 18 de febrero de 2026



Contenido

1	Resumen	4
2	Introducción	6
2.1	Sports Analytics	6
2.2	Medidas de desempeño para jugadores de básquetbol	7
2.3	RAPM (Regularized Adjusted Plus Minus)	8
3	Motivación	9
4	Objetivos	12
4.1	Objetivo general	12
4.2	Objetivos específicos	12
5	Materiales	13
5.1	Generación de la base de datos a partir de técnicas de Web Scraping	14
5.1.1	Listado de links de los partidos	14
5.1.2	Base de datos <i>play-by-play</i>	15
5.1.3	Tabla de jugadores-equipos	17
5.2	Preprocesamiento de los datos	19
5.2.1	Integración del <i>box score</i> con el <i>play-by-play</i>	19
5.2.2	Identificación de los quintetos en cancha al momento de la acción	19
5.2.3	Detección de errores: Carga de los datos	21
5.3	Generación de la base de datos <i>poss-by-poss</i>	22
5.3.1	Eliminación de acciones no relevantes para la posesión	23

5.3.2	Manejo de otro tipo de acciones particulares	23
5.3.3	Identificación de la finalización de las posesiones	26
5.3.4	Cálculo de puntos por posesión	26
5.3.5	Identificación de jugadores ofensivos y defensivos en cancha	27
5.4	Base de datos final: <i>poss-by-poss</i>	27
6	Metodología	28
6.1	Modelos propuestos	28
6.1.1	Modelo de regresión lineal múltiple	28
6.1.2	Modelo logístico multinomial	29
6.2	EPTS y wEPTS	30
6.2.1	EPTS	30
6.2.2	wEPTS	32
6.3	Multicolinealidad	32
6.4	Tratamiento de los jugadores con poco tiempo de juego (<i>Low time players - LTP</i>)	33
6.5	Estimación de los RAPMs	33
6.5.1	Método de mínimos cuadrados	33
6.5.2	Método de máxima verosimilitud	33
6.6	Métodos de regularización	34
6.6.1	Regresión Ridge o Regularización L2	34
6.6.2	Lasso o Regularización L1	35
6.6.3	Elastic Net	36
6.7	Tuneo de hiperparámetros	36

6.8	Comparación de modelos	37
6.8.1	Bondad de ajuste	37
6.8.2	Evaluación de la consistencia de los resultados	37
6.8.3	Criterios de validación externa	37
7	Resultados	38
8	Conclusión	38
9	Discusión	38
10	Bibliografía	40

1 Resumen

El crecimiento de la analítica deportiva ha impulsado el desarrollo de métricas destinadas a evaluar con mayor precisión la contribución de los jugadores al rendimiento de sus equipos. Particularmente en el básquetbol, las estadísticas individuales derivadas del box score presentan limitaciones para capturar el impacto real de los jugadores sobre el resultado del juego. Una de las medidas desarrolladas con este propósito es el *plus-minus*, que registra la diferencia de puntos generada mientras un jugador permanece en cancha. Sin embargo, esta métrica presenta dificultades para aislar el efecto propio de cada jugador respecto del contexto en el que participa. En respuesta a esta problemática surge el *Regularized Adjusted Plus Minus (RAPM)*, una medida basada en modelos estadísticos que estima el impacto ofensivo y defensivo de cada jugador controlando simultáneamente la presencia de compañeros y rivales en cancha.

El objetivo de este trabajo es estimar el impacto individual de los jugadores de la Liga Nacional de Básquetbol de Argentina durante la temporada 2024/2025 mediante modelos RAPM, construyendo rankings que permitan identificar y comparar sus contribuciones ofensivas y defensivas. Asimismo, se analizan distintas alternativas metodológicas para abordar problemas recurrentes en este tipo de modelos, particularmente la multicolinealidad entre jugadores y la presencia de coeficientes extremos asociados a jugadores con escasa participación en cancha.

, las acciones registradas fueron agrupadas en posesiones, que constituyen la unidad de análisis utilizada para la estimación de las métricas propuestas. Inicialmente, se ajustaron modelos de regresión lineal múltiple, incorporando distintas técnicas de regularización. Posteriormente, se implementaron modelos de regresión logística multinomial que representan de manera más adecuada la naturaleza discreta de la variable respuesta. A partir de las probabilidades estimadas por estos modelos se construyeron métricas basadas en puntos esperados por posesión (*EPTS*). Finalmente, se propuso una ponderación a dicha métrica denominada *wEPTS*, que incorpora la participación de cada jugador relativa a las posesiones de su equipo con el objetivo de penalizar a los jugadores con poco tiempo de juego. Los resultados obtenidos muestran que esta métrica presentó un desempeño superior al de las alternativas propuestas, de acuerdo con los distintos

criterios de validación utilizados.

Este estudio constituye la primera aplicación de métricas *RAPM* en la Liga Nacional de Básquetbol de Argentina y aporta una metodología reproducible para la evaluación objetiva del rendimiento individual de los jugadores, contribuyendo al desarrollo de herramientas de analítica deportiva en el contexto del básquetbol argentino.

Palabras clave: básquetbol, analítica en el deporte, Liga Nacional de Básquet, plus-minus, RAPM, regresión logística multinomial, regularización.

2 Introducción

2.1 Sports Analytics

Sports Analytics o analítica en el deporte es un término que refiere a la aplicación de métodos estadísticos para describir, explicar y/o predecir fenómenos vinculados al rendimiento deportivo, tanto a nivel individual como colectivo con el objetivo de facilitar la toma de decisiones de entrenadores o *staff* técnico antes, durante y después de los partidos.

A pesar de que las primeras aplicaciones al análisis de datos al deporte se remontan a mediados del siglo XX, el impulso más significativo ocurrió a partir del año 2000, en particular en el béisbol, con la popularización del enfoque conocido como *sabermetrics*¹. Desde entonces, la práctica se extendió a otros deportes como el básquetbol, el fútbol o el tenis; dando lugar a una nueva cultura de toma de decisiones basada en evidencia. Hoy en día, los equipos profesionales, las ligas y las federaciones emplean departamentos especializados en análisis de datos para optimizar estrategias de juego, evaluar el rendimiento de jugadores, prevenir lesiones y gestionar recursos económicos de manera más eficiente.

El **básquetbol** es uno de los deportes que más ha incorporado el análisis estadístico en su evolución reciente. Desde las primeras métricas derivadas del *box score* (resumen estructurado de los resultados de un partido), el desarrollo de bases de datos *play-by-play* (registro de cada una de las acciones del partido) a partir de la década del 2000 hasta la incorporación más reciente de tecnologías de *player tracking* (sistema que utiliza cámaras y software de visión artificial en los estadios para registrar los movimientos de jugadores y pelotas en tiempo real). A partir de esta información, se han desarrollado distintas herramientas estadísticas para poder estudiar la eficiencia de los jugadores, la eficiencia de los lanzamientos al aro, el desempeño de los equipos, la importancia en la creación de espacios, entre otras cosas.

¹Término utilizado para referirse al análisis estadístico del béisbol, basado en la recopilación y estudio sistemático de datos con el fin de comprender y cuantificar el desempeño de los jugadores y equipos. El nombre proviene de SABR (*Society for American Baseball Research*).

2.2 Medidas de desempeño para jugadores de básquetbol

Desde la consolidación del *box-score* en el básquetbol profesional, durante la década de 1950, empezaron a calcularse las primeras medidas de desempeño para los jugadores, como pueden ser los puntos, rebotes, asistencias, etc. Durante mucho tiempo estas métricas constituyeron una de las formas más tradicionales de evaluar el rendimiento individual en el básquetbol. Su amplia disponibilidad y fácil interpretación las convirtieron en el principal insumo para comparar jugadores, otorgar premios o negociar contratos. Estas medidas suelen agruparse en un conjunto de estadísticas denominadas *bottom-up*, las cuales se calculan en función de las acciones individuales de los jugadores, es decir, si un jugador realiza una acción que se asocia con un resultado positivo para el equipo, la calificación de ese jugador aumenta, mientras que la calificación de los demás jugadores, que no participaron en la jugada, permanece sin cambios. Pero estas medidas presentan algunas limitaciones importantes, ya que, sólo capturan una parte de los eventos relevantes del partido (acciones como una defensa asfixiante, buenas rotaciones defensivas o pases rápidos para iniciar una posesión no están contempladas) y no necesariamente reflejan el impacto real de un jugador en las victorias de su equipo, que es lo que importa a fin de cuentas.

Por otra parte, las medidas *top-down* se basan en el rendimiento del equipo en su conjunto, y el crédito por dicho rendimiento se distribuye entre los jugadores que estuvieron involucrados en el partido, sin importar qué acciones puntuales hayan realizado.

Con la idea de que lo más importante en un partido es **ganar**, y entendiendo que las estadísticas tradicionales son solo una medida imperfecta de muchas de las contribuciones que realizan los jugadores a la victoria, en este trabajo buscaremos “pensar más allá del *box score*” y nos centraremos en estadísticas *top-down*, más precisamente en la medida *Plus/Minus*. Esta estadística registra los cambios que se producen en el marcador durante los minutos en que el jugador de interés está en cancha, partiendo de la idea de que los equipos deberían rendir mejor (reflejado en un *Plus/Minus* más alto) cuando sus buenos jugadores están en cancha que cuando no lo están. Sin embargo esta métrica posee una deficiencia clave: **la calificación**

de cada jugador va a depender en gran medida de la calidad de sus compañeros en el campo. Por ejemplo: un jugador de rol dentro de un gran equipo va a tener un mayor *Plus/Minus* que una superestrella en un equipo con mal desempeño.

2.3 RAPM (Regularized Adjusted Plus Minus)

La deficiencia anteriormente mencionada se ha intentado solucionar implementando **modelos matemáticos** que incorporen los efectos tanto de los compañeros presentes en cancha como de los rivales en ese momento, buscando aislar el efecto real de los jugadores en la cancha. El primero en realizar una publicación sobre el tema fue Dan Rosenbaum (2004), el cual planteó un **modelo de regresión lineal múltiple** en base a observaciones provenientes de partidos de las temporadas 2002-2003 y 2003-2004 de la National Basketball Association o *NBA*. Como unidad de análisis se utilizaron segmentos de partidos donde no ocurrieran sustituciones, la variable respuesta fue la diferencia en el marcador entre el equipo local y el visitante en ese segmento; y como variables explicativas se postularon variables dicotómicas para cada uno de los jugadores que hayan jugado al menos un partido en esas temporadas. Finalmente las métricas de desempeño se correspondían con los coeficientes estimados que acompañaban a las “Dummies” de cada jugador, dichas estimaciones se realizaron mediante la técnica de Mínimos Cuadrados Ordinarios. Estas estadísticas se conocen como *Adjusted Plus Minus* (APM).

A pesar de que estas métricas presentaban una solución innovadora a la problemática inicial, Rosenbaum señaló que las estimaciones obtenidas no resultaron muy precisas. El modelo propuesto presentaba estimaciones con mucho error, debido a un claro problema de **multicolinealidad** ya que muchos de los jugadores compartían una gran cantidad de minutos juntos en cancha, y se necesitaba de una gran cantidad de observaciones de varias temporadas para que el modelo pudiera separar el efecto propio de cada jugador.

Para solucionar esta problemática, se plantea la métrica RAPM introducida por Sill (2010) en la cual se aborda el problema de la Multicolinealidad mediante estimaciones de los parámetros realizadas con Métodos de Regularización, particularmente utilizando la **Regresión Ridge**.

Esté método de regularización es el más abordado a lo largo de toda la literatura relevante sobre RAPM hasta la fecha.

Otro de los problemas recurrentes en estos modelos esta relacionado con la inclusión de jugadores que participan muy pocos minutos en cancha (*LTPs - Low time Players*). Cuando un jugador juega muy poco, el modelo solo tiene unas pocas observaciones (segmentos) para evaluarlo, y si particularmente en esas observaciones el equipo tiene un muy buen desempeño (probablemente por casualidad); entonces el modelo no puede diferenciar si el efecto es propio del jugador y estima coeficientes extremos. Para solucionar estos casos se han contemplado las siguientes alternativas: 1) excluir a los jugadores con pocos minutos dentro de las temporadas (por ejemplo: Rosembaum (2004) excluye a los jugadores con menos de 250 minutos, Ilardi (2007) excluyen a los jugadores con menos de 400 minutos, etc), 2) utilizar una gran cantidad de observaciones (Ilardi & Barzilai (2008) incorpora información de 5 temporadas), 3) plantear métodos de estimación de los parámetros que penalicen a este tipo de jugadores.

En los últimos años, muchos investigadores han publicado trabajos orientados a mejorar los resultados de las métricas RAPM. Particularmente en este trabajo se usa como referencia central al artículo titulado: **Lasso multinomial performance indicators for in-play basketball data (Damoulaki et.al , 2025)**, el cual presenta diferencias importantes respecto de los estudios previos. Dicho artículo utiliza **posesiones** (definidas, según Kubatko et al. (2007), como el periodo que comienza cuando un equipo obtiene el control de la pelota y termina cuando cede su control al rival) como unidad de análisis, **puntos** en esas posesiones como variable respuesta y emplea **modelos logísticos multinomiales** que representan de manera más adecuada la naturaleza de la respuesta.

3 Motivación

El creciente interés por la analítica deportiva que se ha evidenciado en los últimos años en distintos países del mundo, ha empezado a captar la atención de las entidades deportivas en

Argentina. Particularmente este año la Confederación Argentina de Básquetbol (CABB) y la Asociación de Clubes (AdC) anunciaron en octubre la ampliación de su alianza con Catapult (empresa australiana de tecnología deportiva), integrando equipamiento de *wearables* (GPS) y software de videoanálisis para las 19 franquicias de la Liga Nacional, las 34 de la Liga Argentina y las selecciones nacionales en todas las ramas. Mientras que en el ámbito educativo, el Instituto CAB (creado en 2023) realizó un convenio con Sports Data Campus (España) para ofrecer, en agosto de este año, el primer curso de *Big Data aplicado al básquetbol* en Argentina, con el objetivo de que entrenadores y *staff* técnico colaboren en proyectos reales de la CABB, aportando soluciones basadas en datos sobre rendimiento, *scouting* y optimización de procesos².

Estas cuestiones previamente mencionadas dan indicio de que estamos ante un momento ideal para profundizar en el estudio y la aplicación del análisis de datos en el básquetbol. Se trata de un área que comienza a reconocerse como un componente fundamental tanto para mejorar el rendimiento deportivo de los equipos como para impulsar el desarrollo del negocio en torno al deporte. Sin embargo, el potencial de la analítica aplicada al básquetbol en Argentina aún pareciera encontrarse lejos de estar plenamente aprovechado.

En este marco, y con el fin de caracterizar el estado de situación del análisis de datos en el básquet argentino, se relevaron los proyectos e iniciativas actualmente activos en el país vinculados a la estadística y la tecnología aplicada al deporte.

- *CHAS All Stats*, dirigido por Facundo Salas y Sebastián Fiol, ambos entrenadores de básquetbol Nivel 3 Eneba, especialistas en estadísticas avanzadas y analistas de datos en equipos profesionales. Ofrecen servicios de análisis táctico y brindan cursos de estadísticas avanzadas.
- *Básquet Advance*, dirigido por el entrenador Cristian Sánchez, ofrece informes pre/post partido con estadísticas avanzadas y tendencias clave para entrenadores y scouts.

²Confederación Argentina de Básquetbol (2025). *La Confederación Argentina de Básquet y Sports Data Campus firman un acuerdo de colaboración*. Link al artículo.

Ambos proyectos ofrecen herramientas muy importantes y de gran valor tanto para los equipos como para el desarrollo del análisis de datos en el deporte. Pero particularmente en ambos casos, los que llevan adelante estos proyectos son entrenadores de básquetbol, los cuales a pesar de que pueden contar con una sólida formación técnica, no son profesionales de ciencias estadística o matemática.

Por este motivo, resulta fundamental la incorporación de profesionales en carreras de ciencias exactas, que trabajen en conjunto con los entrenadores y cuerpos técnicos, para de esta manera poder ofrecer nuevos análisis más rigurosos y profundos, así como mejorar las herramientas actualmente disponibles. Esta correspondencia entre el conocimiento técnico-deportivo y el enfoque estadístico permitiría potenciar el desarrollo del básquet argentino y contribuir a elevar su nivel competitivo en un futuro.

4 Objetivos

4.1 Objetivo general

El objetivo general de esta tesina es estimar el aporte individual de los jugadores de la Liga Nacional de Básquetbol de Argentina durante la temporada 2024/2025 mediante modelos RAPM, con el fin de construir un ranking que refleje su impacto en el desempeño de sus equipos.

4.2 Objetivos específicos

- 1) Generar una base de datos del tipo *play-by-play* para la temporada 2024/2025 de la Liga Nacional de Básquetbol de Argentina, mediante técnicas de *web scraping*.
- 2) Diferenciar el aporte ofensivo y defensivo de cada uno de los jugadores de la liga, obteniendo finalmente rankings que identifiquen a los mejores jugadores en cada rubro.
- 3) Desarrollar una metodología adecuada que permita solucionar el problema de los coeficientes extremos asociados a los jugadores con pocos minutos de juego (*LTPs Players*) durante la temporada.
- 4) Comparar modelos en base a distintos criterios de evaluación, para poder determinar cual de ellos proporciona mejores métricas, debiendo resumir de manera consistente y precisa el aporte ofensivo y defensivo de cada jugador en relación al desempeño de su equipo.

— Modificación del objetivo —

Recibí el siguiente comentario de parte de los jurados en la corrección del anteproyecto:

“Actualmente el objetivo enfatiza la construcción de un ranking. Te sugiero reformularlo poniendo mayor énfasis en la evaluación y comparación metodológica de los distintos enfoques de estimación (modelo lineal vs. multinomial, distintas penalizaciones, etc.). El ranking debería presentarse como un resultado del análisis, no como el eje central del trabajo.”

A pesar de que mi idea era centrar la tesis en encontrar un ranking óptimo (objetivo general) y para esto comparar distintos modelos (objetivo específico 4), pienso que tiene razón de ser este comentario al ser una tesina de estadística más que una tesina vinculada al deporte. Mis objetivos modificados serían los siguientes, quedó atento a su opinión al respecto.

Objetivo general:

El objetivo general de esta tesina es evaluar y comparar diferentes enfoques de estimación de modelos RAPM para cuantificar el impacto individual de los jugadores de la Liga Nacional de Básquetbol de Argentina durante la temporada 2024/2025.

Objetivo específico 4:

Generar rankings definitivos de la Liga Nacional como el resultado final obtenido mediante el modelo óptimo, identificando a los mejores jugadores de cada rubro para la temporada en estudio.

5 Materiales

Una parte central de esta tesina estará dedicada a la construcción de una base de datos *play-by-play* correspondiente a la temporada 2024/2025 de la Liga Nacional de Básquetbol de Argentina (LNB). Este tipo de base registra de manera secuencial todas las acciones ocurridas dentro de un partido. Dado que no existe una fuente oficial que provea los datos en formato estructurado y descargable para su análisis estadístico, fue necesario diseñar y ejecutar un proceso de *web scraping* que permita recolectar, integrar y depurar la información de manera sistemática y reproducible. Los datos necesarios se extrajeron del Sitio Oficial de la Liga Nacional de Básquet, utilizando librerías de Python como `Selenium` y `BeautifulSoup`.


Posteriormente, se realizó un preprocesamiento orientado a transformar los eventos crudos en un *dataset* apto para la aplicación de los modelos mencionados anteriormente. Como resultado, se obtuvo una tabla ordenada cronológicamente en la cual cada fila corresponde a una posesión del partido, contabilizando los puntos anotados durante esa posesión y los jugadores que formaron

parte de la misma, diferenciando sus roles ofensivos y defensivos. Debido a que bajo esta metodología se registran cada una de las posesiones del partido de manera secuencial, se denominó a esta estructura final como: base de datos *poss-by-poss*.

5.1 Generación de la base de datos a partir de técnicas de Web Scraping

5.1.1 Listado de links de los partidos

El primer paso consistió en la identificación y recopilación de los enlaces a las páginas webs que contienen las estadísticas individuales de todos los partidos incluidos en el período de estudio (378 partidos de temporada regular). Para ello, se accedió a la página de la Liga Nacional, sección Fixture, la cual presenta una tabla dinámica con los encuentros disputados y permite acceder a la información detallada de cada partido.



Desde	Hasta	Local	Visitante	Fecha/Hora - Campo	Estadísticas
01/01/2025	01/02/2026	BOCA	82 67	RACING (CH) 24/09/2025 21:30 LUIS CONDE	
		PLATENSE	82 87	FERRO 25/09/2025 20:30 CIUDAD DE VICENTE LOPEZ	
		LA UNION FSA.	85 91	REGATAS (C) 25/09/2025 21:00 CINCUENTENARIO	
		QUIMSA	72 73	INSTITUTO 25/09/2025 21:30 CIUDAD	
		SAN LORENZO	82 74	PEÑAROL (MDP) 26/09/2025 20:30 ROBERTO PANDO	
		SAN MARTÍN (C)	76 49	ATENAS (C) 26/09/2025 21:00 RAUL ARGENTO ORTIZ	

Figura 1: Fixture dentro de la página web de la LNB.

En la Figura 1 se muestra la interfaz del sitio web, donde se visualiza el listado completo de partidos de la temporada para el rango de fechas seleccionadas. Dado que no pudo automatizarse la obtención de cada uno de estos links, se procedió a copiar manualmente el *DOM* (*Document Object Model*) de la página y a pegarlo en un archivo de texto.




Figura 2: Inspección de la página web.

A partir de dicho archivo de texto, se utiliza la librería BeautifulSoup de Python para recorrer la estructura del DOM, identificando previamente los elementos que contienen los enlaces de cada partido. Se observa en la Figura 2 que la información de cada partido se encuentra dentro de las clases “fila-tabla-calendarios-datos-estadisticos”, por lo cual se recorren estas clases obteniendo los respectivos enlaces a las páginas de estadísticas de cada partido, los nombres de los equipos participantes y el resultado del encuentro, para cada uno de los 378 partidos disputados en la temporada regular. Obteniendo finalmente un diccionario que contenga toda esta información. Dicho diccionario constituyó el insumo básico para el proceso posterior de scraping masivo, sobre los cuales se iterará para obtener así la información correspondiente a cada una de las acciones registradas en cada partido. Esta estrategia permitió, además, asegurar la reproducibilidad del proceso, ya que el listado de partidos es eliminado de la página web una vez terminada la temporada, quedando fijado y documentado de manera explícita para su uso, en caso de ser requerido.

5.1.2 Base de datos *play-by-play*

Una vez obtenido el listado completo de enlaces correspondientes a cada uno de los partidos en el período de estudio, se procedió a la extracción del registro de acciones del partido (*play-by-play*). Para esto, se accedió individualmente a la página de estadísticas de cada encuentro,

particularmente a la pestaña denominada “en vivo”, donde se presenta el detalle secuencial de los eventos.

Como se observa en la Figura 3, esta sección del sitio web contiene una tabla que se genera dinámicamente y que registra, en orden cronológico, todas las acciones ocurridas durante el partido.




Figura 3: Pestaña en vivo dentro de la página web de estadísticas de un partido

En dicha tabla, cada acción del partido se encuentra representada como un elemento que incluye información textual sobre el tipo de acción (por ejemplo, lanzamiento convertido, falta, pérdida, etc), el jugador que realiza dicha acción, el cuarto de juego, el tiempo restante en el cuarto y , en caso de ser una acción donde se generan puntos, el marcador parcial en ese momento del partido. Esta información fue sistemáticamente extraída y almacenada en una estructura tabular, conservando el orden temporal de las acciones.

Este procedimiento se aplicó de forma idéntica a todos los partidos de la temporada analizada,

utilizando como insumo los enlaces previamente identificados. Finalmente, los registros de acciones obtenidos para cada encuentro fueron concatenados en una única base de datos de *play-by-play*, incorporando un identificador de partido que permite distinguir y vincular las acciones correspondientes a cada juego. Asimismo, a partir de esta clave única asociada al encuentro (por ejemplo, GIMNASIA (CR) vs REGATAS (C) (03/05/2025 20:30)), fue posible identificar e incorporar a la base el equipo local y visitante correspondiente a cada partido. Esta información resultó útil en etapas posteriores del procesamiento donde al conocer el equipo asociado a cada acción, puede inferirse la condición del mismo (local o visitante).

Es importante destacar que el *dataset* resultante constituye una secuencia detallada de eventos, pero en su forma original no incluye una identificación explícita del equipo asociado a cada acción, lo cual resulta indispensable a la hora de realizar los análisis posteriores.

5.1.3 Tabla de jugadores-equipos

Para resolver este problema, se obtuvo dicha información a partir de los datos provenientes del *Box Score*, localizados en la pestaña “Estadísticas” de la página web del partido (Figura 4). Aquí encontraremos información referida a cada uno de los jugadores anotados en la planilla de ambos equipos.

Figura 4: Ejemplo del Box Score de un partido

En esta pestaña, la información se organiza en dos tablas con estadísticas individuales de los jugadores, una correspondiente al equipo local y otra al equipo visitante, las cuales aparecen en el mismo orden en que se muestran los nombres de los equipos en la interfaz del sitio web. A partir de esta estructura, se extrajo para cada jugador su nombre completo, el equipo al que pertenece y la cantidad de minutos disputados en dicho partido, generándose así una tabla de correspondencia jugador–equipo.

Esta tabla constituye un diccionario que permite asociar a cada jugador con su respectivo equipo, y es utilizada posteriormente como insumo para realizar dicha correspondencia en cada acción de la base *play-by-play*. A su vez, mediante la adición de la cantidad de minutos en el partido se realiza un filtrado de jugadores que hayan participado menos de cierto umbral requerido de tiempo durante la temporada, cuestión fundamental a tratar posteriormente en este trabajo.

5.2 Preprocesamiento de los datos

5.2.1 Integración del *box score* con el *play-by-play*

Una vez construida la tabla jugadores-equipos, se procedió a integrar dicha información con la base de datos *play-by-play*. Para ello, los nombres de los jugadores fueron previamente normalizados con el objetivo de reducir posibles inconsistencias de formato (espacios adicionales, diferencias menores de escritura), y luego se utilizó la correspondencia jugador–equipo para asignar a cada acción del *play-by-play* el equipo del jugador involucrado.

De este modo, cada acción queda asociada explícitamente a uno de los dos equipos del partido, aun cuando dicha información no se encuentre disponible de forma directa en el registro original del *play-by-play*. Este procedimiento permite identificar qué jugadores estarán en cancha para cada uno de los equipos, permitiendo construir los quintetos en cada momento del partido.

5.2.2 Identificación de los quintetos en cancha al momento de la acción

A partir de la nueva tabla generada, se procedió a construir la presencia de los jugadores en cancha a lo largo del partido. Para ello, se identificaron las acciones asociadas a sustituciones, distinguiendo entre entradas (acción = ENTRA A PISTA) y salidas de jugadores (acción = ABANDONA LA PISTA), tal como se observa en la Figura 5.




Figura 5: Ejemplo de secuencia de acciones con sustitución

El conjunto de jugadores en cancha se actualiza a medida que se recorren las acciones del partido, reiniciándose al comienzo de cada cuarto. De este modo, para cada instante del juego se obtiene el conjunto de jugadores activos en cancha.

Utilizando la tabla jugadores-equipos construida previamente, cada jugador en cancha fue asignado al equipo local o visitante, permitiendo reconstruir los quintetos de ambos equipos en cada acción del partido. Este paso resulta esencial para caracterizar el contexto en el que ocurre cada acción, ya que al conocer el equipo al que pertenece el jugador que realiza la acción podemos inferir simultáneamente los jugadores ofensivos y defensivos presentes en cancha en cada momento.

Una vez reconstruidos los quintetos en cancha para cada acción, se incorporó un control de consistencia basado en la cantidad total de jugadores activos. Dado que una situación de juego regular involucra diez jugadores (cinco por equipo), se podrán identificar aquellas acciones en las que la cantidad total de jugadores en cancha fuera superior o inferior a dicho umbral.

5.2.3 Detección de errores: Carga de los datos

Un factor importante a tener en cuenta es que los datos que se encuentran en el *play-by-play* son cargados de manera manual por las mesas de control a medida que se desarrolla el partido. Esta tarea se realiza en el contexto altamente dinámico de un partido, donde las acciones se suceden con rapidez, lo que puede dar lugar a ciertos errores en la registración de eventos. En consecuencia, el conjunto de datos original puede contener inconsistencias que deben ser identificadas y corregidas antes de su utilización en este trabajo.

Para intentar detectar posibles errores en la conformación de los quintetos en cancha, se construyó , tal como se menciono anteriormente, una variable que contabiliza la cantidad de jugadores presentes en cada quinteto en cada una de las acciones del partido. Dicha variable debería contabilizar un valor menor a cinco para ambos equipos en todas las acciones registradas.

De esta manera se detectó un caso puntual en el partido de ZARATE BASKET vs ATENAS

(C), donde el quinteto local registraba 6 jugadores en cancha. Esta inconsistencia se observó desde el inicio del segundo cuarto (con 10:00 minutos restantes) hasta el minuto 4:42 del mismo período.

Para subsanar este inconveniente, se realizó una revisión manual del *play-by-play* original disponible en la página web y se pudo identificar que al comienzo del segundo cuarto se había registrado incorrectamente el ingreso de seis jugadores en lugar de cinco, lo cual constituye un error atribuible a la mesa de control. Una vez identificada esta problemática, se revisó el contexto de las siguientes jugadas y pudo determinarse que el jugador MERCHANT, EDGAR HENRY no se encontraba realmente en cancha durante ese tramo del partido.

En consecuencia, se procedió a corregir el error eliminando al jugador mencionado de la variable correspondiente al quinteto local en las acciones afectadas, así como ajustando el conteo de jugadores en cancha. De esta manera, se restauró la consistencia lógica de los quintetos y se garantizó la validez de la información utilizada en las etapas posteriores del análisis.

5.3 Generación de la base de datos *poss-by-poss*

Como resultado de las etapas anteriores, pudimos obtener una base de datos unificada donde cada fila se corresponde con cada una de las jugadas o acciones que suceden dentro del partido, incluyendo información relevante para este trabajo como lo es el marcador del partido al momento de la acción, la composición de los quintetos en cancha y la condición de local o visitante. Sin embargo, para poder aplicar los modelos estadísticos mencionados, resulta necesario agrupar estas acciones en **posesiones**, entendidas como el conjunto de acciones ocurridas antes de que cambie el control de la pelota.

Para llevar a cabo este proceso fue necesario definir una metodología adecuada que permita diferenciar qué acciones pertenecían a una misma posesión, y en qué momento comenzaba una distinta.

5.3.1 Eliminación de acciones no relevantes para la posesión

Este procedimiento no pudo realizarse de manera directa, ya que, a pesar de contar con la información secuencial sobre el que equipo realizaba cada acción, no todo cambio en el equipo asociado a una acción implica necesariamente un cambio de posesión del balón. Existen situaciones en las que se registran acciones del equipo defensor dentro de una posesión del equipo atacante. A los cuales se ha decidido por llamar como “acciones intrusas”. Un ejemplo de la contabilización correcta e incorrecta de las posesiones a partir de la secuencia de acciones se presenta en la Figura 6.




Figura 6: Comparación entre distintas formas de contabilizar las posesiones

Luego de hacer una revisión manual en un conjunto limitado de partidos, se llegó a la definición de que el conjunto de acciones presentes en el Cuadro 1 suelen ser siempre acciones intrusas o nunca resultan informativas para la delimitación de las posesiones. En consecuencia se ha decidido eliminar las filas en las que ocurren estas acciones en la base de datos.

Estas acciones son:

5.3.2 Manejo de otro tipo de acciones particulares

1) Tratamiento de la flecha de alternancia

En el básquetbol bajo reglamento FIBA, la flecha de alternancia determina la posesión del balón en los inicios de cuarto o en situaciones de salto entre dos. Cuando este evento aparece

Cuadro 1: Acciones eliminadas por no ser informativas para la delimitación de las posesiones

N°	Acción
1	ENTRA A PISTA
2	INICIO DEL PERIODO
3	FINAL DEL PERIODO
4	ABANDONA LA PISTA
5	TAPON REALIZADO
6	TECNICA
7	TECNICA BANQUILLO (C)
8	TECNICA BANQUILLO (B)
9	TECNICA DESCALIFICANTE
10	TECNICA DESCALIFICANTE ACOMPAÑANTE NO PARTICIPA
11	TECNICA-E (ALINEACIÓN ILEGAL)
12	TIEMPO MUERTO SOLICITADO
13	ANTIDEPORTIVA

registrado en el *play-by-play*, el equipo que obtiene la posesión es el opuesto al que figura inicialmente asociado a la acción.

Para corregir este comportamiento, se implementó una regla que invierte el equipo asignado a la acción en presencia de una flecha de alternancia, garantizando la correcta identificación del equipo en control del balón.

2) Eliminación de rebotes defensivos al final de cada cuarto

Se detectó que, en algunos casos, el *play-by-play* registra un rebote defensivo como última acción de un cuarto. Ya que esta situación sucede quedando unos pocos segundos para terminar el cuarto, no debe ser contabilizada como una posesión real, y para evitar dichas situaciones se eliminó dichas acciones de la base de datos.

3) Reglas específicas para el tratamiento de faltas ofensivas

Las faltas ofensivas representan un caso particular dentro del *play-by-play*, ya que no son diferenciadas de las faltas defensivas en la descripción de la acción, y tienen una diferencia fundamental a la hora de definir las posesiones. Por un lado, las faltas defensivas corresponden a una “acción intrusa” y deben ser eliminadas de la base, mientras que las faltas ofensivas

siempre implican un cambio inmediato de posesión y, en ocasiones, pueden ser la única acción que realice un equipo dentro de una posesión, como se observa en la Figura 7. Por lo que en esos casos puntuales dicha acción debe conservarse.

En consecuencia, se desarrolló un conjunto de reglas basadas en el contexto de la acción previa para decidir si una falta debe ser conservada o eliminada del registro. Particularmente, se definió que: una falta debe conservarse si el equipo que la comete es distinto al equipo que realizó la acción inmediata anterior, siempre que dicha acción previa sea:

- 1) un lanzamiento fallido.
- 2) una pérdida de balón.
- 3) Una anotación con una separación temporal suficiente que indique el transcurso de una nueva posesión.

Todas las faltas que no cumplieran esta condición fueron eliminadas para evitar errores en el conteo de posesiones.



Figura 7: Ejemplo de falta ofensiva en una secuencia de acciones

5.3.3 Identificación de la finalización de las posesiones

Una vez realizada esta tarea de preprocesamiento anteriormente mencionada, se incorporó un identificador preliminar de posesión, basado en dos criterios fundamentales: el cambio de equipo en control del balón y el cambio de cuarto. De manera que cada vez que ocurre alguno de estos eventos, se identifica como el inicio de una nueva posesión. Esto se encuentra ejemplificado en el Cuadro 2.

Cuadro 2: Ejemplo de secuencia de acciones diferenciando cada posesión

Cuarto	Tiempo	Acción	Jugador	Equipo	...	Posesión
1	00:08:54	TIRO DE 3 FALLADO	STENTA, NICOLAS	BOCA		4
1	00:09:12	REBOTE DEFENSIVO #11	VILDOZA, JOSE IGNACIO	BOCA		4
1	00:09:13	TIRO DE 3 FALLADO	BUENO, CARLOS EMANUEL	ATENAS		3
1	00:09:18	FALTA RECIBIDA	BUENDIA, CARLOS MANUEL	ATENAS		3
1	00:09:31	ASISTENCIA	VILDOZA, JOSE IGNACIO	BOCA		2
1	00:09:32	TRIPLE	PIÑERO, FACUNDO	BOCA		2
1	00:09:42	REBOTE DEFENSIVO #11	VILDOZA, JOSE IGNACIO	BOCA		2
1	00:09:43	TIRO DE 2 FALLADO	OBERTO, JUAN CRUZ MATEO	ATENAS		1

De este modo, se seleccionaron las filas correspondientes a los eventos finales de cada posesión, descartando las acciones intermedias que no determinan su conclusión.

5.3.4 Cálculo de puntos por posesión

Para obtener la cantidad de puntos obtenidos en cada posesión, se calculó la diferencia entre el puntaje acumulado del equipo atacante al final de la posesión y el puntaje acumulado registrado al cierre de la posesión inmediatamente anterior. De esta manera, cada posesión queda caracterizada por una variable discreta que representa su resultado ofensivo en términos de puntos anotados. Tal como se presenta en el Cuadro 3.

Cuadro 3: Ejemplo de estructura con una fila por posesión

Cuarto	Tiempo	Acción	Jugador	Equipo	...	Posesión	Puntos
1	00:08:54	TIRO DE 3 FALLADO	STENTA, NICOLAS	BOCA		4	0
1	00:09:13	TIRO DE 3 FALLADO	BUENO, CARLOS EMANUEL	ATENAS		3	0
1	00:09:31	ASISTENCIA	VILDOZA, JOSE IGNACIO	BOCA		2	3
1	00:09:43	TIRO DE 2 FALLADO	OBERTO, JUAN CRUZ MATEO	ATENAS		1	0

5.3.5 Identificación de jugadores ofensivos y defensivos en cancha

Con el objetivo de poder distinguir la participación individual de los jugadores en cada posesión, se utilizó la información de los quintetos en cancha previamente reconstruidos durante el preprocesamiento. Para cada posesión se identificaron los cinco jugadores del equipo atacante y los cinco jugadores del equipo defensor.

A partir de esta información se construyó una representación matricial de jugadores por posesión, donde cada jugador de la temporada cuenta con dos variables indicadora. En la cual, la primer variable dummy asigna a cada jugador un 1 si el jugador forma parte del quinteto ofensivo y 0 en caso contrario; mientras que la segunda variable dummy asigna un -1 si el jugador forma parte del quinteto defensivo, y 0 en otro caso. Este esquema permite modelar de manera explícita la contribución ofensiva y defensiva de manera independiente/separada para cada uno de los jugadores que han participado en al menos un partido dentro de la temporada en estudio.

5.4 Base de datos final: *poss-by-poss*

A través de este proceso, se generó una base de datos que permitirá modelar la cantidad de puntos por posesión teniendo en cuenta los jugadores presentes en cancha, dicha base cuenta con la información correspondiente a 58.625 posesiones, asociadas a 378 partidos disputados en la temporada en estudio.

Las variables presentes son las siguientes:

puntos = Cantidad de puntos en la posesión.

cuarto = Cuarto en el que se desarrollo la posesión.

tiempo = Tiempo restante del cuarto en el momento que finaliza la acción.

equipo = Nombre del equipo que está atacando en la posesión.

condicion = Condición de localia del equipo que está atacando en la posesión.

6 Metodología

En base a los objetivos planteados en esta tesina de grado, se compararán resultados provistos por modelos con distintas características, con el fin de poder sintetizar la contribución ofensiva y defensiva de los jugadores de manera adecuada. Para poder identificar que modelo es el que brinda mejores resultados, también se definirá un procedimiento adecuado para evaluarlos.

Los distintos modelos utilizados, las formas de estimar los parámetros y los métodos de comparación de modelos se definen a continuación.

6.1 Modelos propuestos

6.1.1 Modelo de regresión lineal múltiple

Los modelos más comunmente utilizados en la literatura relevante sobre RAPMs son los modelos de regresión lineal múltiple, los cuales van a modelar el comportamiento de la variable respuesta *Puntos en la posesión i* (y_i) en función de $P = 2K$ variables explicativas dicotómicas, correspondientes a las apariciones ofensivas y defensivas de K jugadores.

El componente aleatorio supone que las respuestas y_i tienen variancias constantes σ^2 . De esta manera tenemos que,

$$\begin{cases} y_i \sim N(\mu_i, \sigma^2) \\ \mu_i = \beta_0 + \sum_{j=1}^K \beta_j^o x_{ji}^o + \sum_{j=1}^K \beta_j^d x_{ji}^d \end{cases}$$

para $i = 1, \dots, n$;

Donde:

n : es el número total de posesiones en nuestro dataset, K : es el número total de jugadores en consideración, y_i : es el número de puntos realizados en la posesión i (los puntos en una posesión pueden variar de 0 a 7, siendo los casos en que se anotan 6 o 7 puntos, jugadas

extremadamente atípicas), μ_i : es la cantidad esperada de puntos anotados en la posesión i , x_{ik}^o : indicadora ofensiva del jugador k en la posesión i (1 si el jugador k estaba jugando en ataque en la posesión i , 0 en otro caso), x_{ik}^d : indicadora defensiva del jugador k en la posesión i (-1 si el jugador k estaba jugando en defensa en la posesión i , 0 en otro caso), β_0 : Intercepto del modelo (usualmente representa al jugador de referencia, definido como aquel con coeficientes RAPM iguales o cercanos a cero), β_k^o : coeficiente ofensivo del jugador k (*ORAPM*), β_k^d : coeficiente defensivo del jugador k (*DRAPM*).

Como $\hat{\beta}_j$ es una combinación lineal de y_j , entonces la distribución de estos parámetros es conocida. Tenemos que:

$$\hat{\beta}_j \sim N(\beta_j, \text{var}[\hat{\beta}_j])$$

Este modelo es de sencilla aplicación y ha sido ampliamente utilizado por distintos analistas que trabajan con este tipo de métricas. Sin embargo, la variable respuesta en este caso es discreta, tomando valores enteros entre 0 y 6, lo que sugiere que el supuesto de normalidad del modelo de regresión lineal múltiple no resulta apropiado para representar adecuadamente la naturaleza de la variable de interés.

6.1.1.1 Interpretación de los coeficientes ...

6.1.2 Modelo logístico multinomial

En consecuencia a lo comentado anteriormente, podría ser más razonable emplear un modelo que contemple la distribución discreta de los datos. Por lo que se procede a la implementación de una regresión logística multinomial para modelar el resultado en puntos de cada posesión.

Recordando que y_i es igual a la cantidad de puntos en una posesión, nuestra nueva variable respuesta resulta:

$$y_i^M = \begin{cases} y_i, & \text{para } y_i \in \{0, 1, 2\} \\ 3, & \text{para } y_i \geq 3 \end{cases}$$

Donde, $y_i^M \sim Multinomial(n, \boldsymbol{\pi}_i)$ con $\boldsymbol{\pi}_i = (\pi_{i0}, \pi_{i1}, \pi_{i2}, \pi_{i3})$ y $\sum_{c=0}^3 \pi_{ic} = 1$.

Resultando $\pi_{i0}, \pi_{i1}, \pi_{i2}$ y π_{i3} las probabilidades respectivas de no anotar, de anotar 1 punto, de anotar 2 puntos y de anotar 3 puntos o más en la posesión i .

Luego construimos el modelo logístico multinomial con categoría de referencia, eligiendo como categoría de referencia a 0 puntos anotados:

$$\text{logit}(\pi_{ic}) = \log\left(\frac{\pi_{ic}}{\pi_{i0}}\right) = \beta_{0c} + \sum_{j=1}^K \beta_{jc}^o x_{ji}^o + \sum_{j=1}^K \beta_{jc}^d x_{ji}^d \quad \text{con } c = \{1, 2, 3\}$$

Dicho modelo describe el efecto de los jugadores en cada uno de los $c - 1 = 3$ logits, es decir, va a permitir calcular el aporte ofensivo y defensivo del jugador para cada tipo de anotación.

Las probabilidades multinomiales se obtienen mediante las siguientes ecuaciones:

$$\pi_{ic} = \frac{\exp(\mathbf{x}_i^T \boldsymbol{\beta}_i)}{1 + \sum_{c=1}^3 \exp(\mathbf{x}_i^T \boldsymbol{\beta}_i)}$$

6.1.2.1 Interpretación de los coeficientes ...

6.2 EPTS y wEPTS

6.2.1 EPTS

En el enfoque mencionado anteriormente los coeficientes $\{\beta_1^o, \beta_2^o, \beta_3^o\}$ y $\{\beta_1^d, \beta_2^d, \beta_3^d\}$ representan las contribuciones de cada jugador en los distintos tipos de anotación. Aunque puede resultar interesante y permita realizar distintos análisis, el objetivo final de este estudio es obtener una métrica que unifique la contribución ofensiva y defensiva en una única medida general.

Para la contribución ofensiva, esto puede lograrse calculando la cantidad de puntos esperada en una posesión que anota el equipo de dicho jugador cuando el está incluido en el quinteto y todos los demás jugadores en la alineación pertenecen al grupo de referencia (con RAPM igual a 0).

Para la contribución defensiva de un jugador puede evaluarse mediante la cantidad esperada de puntos (por posesión) concedidos por el equipo de dicho jugador cuando él no está en la alineación y todos los demás jugadores en cancha pertenecen al grupo de referencia.

A esta nueva métrica la denominamos ETPS (*Expected Points per Team possession with the player Scoring contribution*)

$$EPTS_k^r = E(PTS_i \mid X_{ik}^r \neq 0, \mathbf{X}_{i/k}^r = 0, \mathbf{X}_i^{\bar{r}} = 0), \quad r \in \{o, d\}$$

Estas dos medidas, $ETPS^o$ y $ETPS^d$, serán funciones de los coeficientes ofensivos y defensivos del modelo multinomial ajustado. Se obtienen mediante:

$$EPTS_k^r = \pi_{k1}^r + 2\pi_{k2}^r + 3,01\pi_{k3}^r, \quad r \in \{o, d\}$$

Donde π_{kc}^o son las probabilidades estimadas mediante un modelo de regresión logística multinomial de anotar uno, dos o tres puntos o más, respectivamente, por posesión del equipo del jugador k cuando él está incluido en la alineación y todos sus compañeros de equipo en la alineación y todos los oponentes son jugadores incluidos en el grupo de referencia (es decir, aquellos con coeficientes de regresión iguales a cero).

De manera similar, π_{kc}^d son las probabilidades de anotar uno, dos o tres puntos o más, respectivamente, por posesión por parte del equipo oponente del jugador k cuando dicho jugador no está incluido en la alineación, bajo el mismo escenario.

Estas probabilidades vienen dadas por:

$$\pi_{kc}^r = \frac{\exp(\mu_{kc}^r)}{1 + \exp(\mu_{k1}^r) + \exp(\mu_{k2}^r) + \exp(\mu_{k3}^r)} \quad \text{con } \mu_{kc}^r = \beta_{0c} + \beta_{kc}^r$$

6.2.2 wEPTS

Una versión mejorada y ponderada de los EPTS se calcula en *Damoulaki et.al (2025)*, la cual tiene en cuenta la participación del jugador a lo largo de la temporada. En la cual la métrica anteriormente presentada se pondera según la proporción de posesiones en las que el jugador de interés estuvo en cancha. Por lo tanto, el EPTS ponderado (wEPTS) se define como:

$$\begin{aligned} wEPTS_k^r &= E(Pts_i \mid \mathbf{X}_{i \setminus k}^r = \mathbf{0}, \mathbf{X}_i^{\bar{r}} = \mathbf{0}, T_i = t_k) \\ &= P(X_{ik}^r \neq 0 \mid T_i = t_k) E(Pts_i \mid X_{ik}^r \neq 0, \mathbf{X}_{i \setminus k}^r = \mathbf{0}, \mathbf{X}_i^{\bar{r}} = \mathbf{0}) \\ &\quad + P(X_{ik}^r = 0 \mid T_i = t_k) E(Pts_i \mid X_{ik}^r = 0, \mathbf{X}_{i \setminus k}^r = \mathbf{0}, \mathbf{X}_i^{\bar{r}} = \mathbf{0}) \\ &= W_k^r EPTS_k^r + (1 - W_k^r) EPTS_0 \end{aligned}$$

donde $r \in \{o, d\}$. Además, el peso W_k^r se estima como:

$$\hat{W}_k^r = \frac{n_k^r}{n_{t_k}^r} = \frac{\sum_{i=1}^n \mathcal{I}(X_{ik}^r \neq 0)}{\sum_{i=1}^n \mathcal{I}(T_i^r = t_k)}.$$

Ahora tenemos que $\mathcal{I}(A)$ es una variable indicadora que vale 1 en caso de que A sea verdadero y 0 en caso contrario, T_i^k es el equipo en ataque ($r = o$) o en defensa ($r = d$) en la posesión i, t_k es el equipo del jugador k , n_k^r es el número de posesiones en las que el jugador k participó en el quinteto en ataque o defensa en la temporada y $n_{t_k}^r$ es el número de posesiones en las que el equipo del jugador k está en ataque o defensa en la temporada.

6.3 Multicolinealidad

...

6.4 Tratamiento de los jugadores con poco tiempo de juego (*Low time players - LTP*)

...

6.5 Estimación de los RAPMs

6.5.1 Método de mínimos cuadrados

En el modelo de regresión lineal múltiple, vamos a estimar los parámetros buscando minimizar las diferencias entre las observaciones de nuestro dataset y las estimaciones del modelo,

Función a minimizar: $S = \sum_{i=1}^n w_i (y_i - \mu_i)^2$

Los estimadores de mínimos cuadrados de β_j se definen como aquellos valores de β_j que minimizan la suma de cuadrados S , y se denotan como $\hat{\beta}_0, \dots, \hat{\beta}_p$.

Obteniendo de esta manera los siguientes coeficientes estimados: $\hat{\beta}_j = \frac{\sum_{i=1}^n w_i x_{ij}^* y_i}{\sum_{i=1}^n w_i (x_{ij}^*)^2}$,

para $j = 0, \dots, p$, donde x_{ij}^* da los valores de la j -ésima variable explicativa x_j después de haber sido ajustada por todas las demás variables explicativas $x_0, \dots, x_p$ excepto x_j . La variable explicativa ajustada x_j^* es aquella parte de x_j que no puede ser explicada mediante una regresión sobre las otras variables explicativas (Dunn y Smyth, 2018).

6.5.2 Método de máxima verosimilitud

En el modelo logístico multinomial, los parámetros $\beta_0, \beta_1, \dots, \beta_p$ se estiman utilizando simultáneamente las $(c-1)$ ecuaciones logit, de manera que se maximice la log-verosimilitud:

Función a maximizar: $L_m(\beta, \mathbf{y}) = \sum_{i=1}^n w_i \sum_{j=1}^c y_{ij} \log(\pi_{ij})$,

Como esto no tiene una solución cerrada, debe recurrirse a algoritmos iterativos como *Newthon-Rapshon* o *Fisher-Scoring* para obtener los resultados.

6.6 Métodos de regularización

Como se ha mencionado anteriormente, el modelo planteado presenta variables predictoras altamente correlacionadas debido a que muchos de los jugadores comparten gran parte del tiempo en cancha, por lo que el ajuste con mínimos cuadrados ordinarios o mediante máxima verosimilitud se torna inestable. Con el objetivo de solucionar este problema se realizarán estimaciones mediante métodos de regularización (o *shrinkage*), los cuales agregan un término de penalización a la función de pérdida para de esta manera controlar la magnitud de los coeficientes estimados. Esta técnica va a provocar que las estimaciones sean sesgadas, pero a cambio de una notable reducción en la variancia.

Las técnicas que se utilizarán en esta investigación son las siguientes:

6.6.1 Regresión Ridge o Regularización L2

Este método incorpora una penalización cuadrática sobre los coeficientes del modelo.

Para el **modelo de regresión lineal múltiple** los coeficientes estimados $\hat{\beta}$ se obtienen minimizando la función de pérdida (S) modificada de la siguiente manera:

$$S^* = \sum_{i=1}^n w_i (y_i - \mu_i)^2 + \lambda \sum_{j=1}^p \beta_j^2 = S + \lambda \sum_{j=1}^p \beta_j^2$$

Donde $\lambda \geq 0$ es un *hiperparámetro* que controla la intensidad de la penalización.

Cuando $\lambda = 0$ no hay penalización y la estimación será igual a la obtenida por mínimos cuadrados; y a medida que λ aumenta la penalización se vuelve más dominante y los coeficientes tienden a 0. Para encontrar el valor óptimo de λ se utilizarán técnicas de **validación cruzada**.

Mientras que en el caso del **modelo logístico multinomial**, se agrega un parámetro de penalización a la función de log-verosimilitud, de manera tal que la log-verosimilitud penalizada a maximizar resulta:

$$L_m^*(\boldsymbol{\beta}, \mathbf{y}) = \sum_{i=1}^n w_i \sum_{j=1}^c y_{ij} \log(\pi_{ij}) + \lambda \sum_{j=1}^p \beta_j^2 = L_m(\boldsymbol{\beta}, \mathbf{y}) + \lambda \sum_{j=1}^p \beta_j^2$$

Y el *hiperparámetro* λ se selecciona nuevamente mediante validación cruzada.

6.6.2 Lasso o Regularización L1

A diferencia de la regresión Ridge, en la cual los coeficientes pueden acercarse a 0 pero nunca llegan exactamente a ese valor, la técnica Lasso, presentada por Robert Tibshirani (1996), tiende a forzar algunos parámetros a ser cero, con lo cual también se realiza una selección de las variables/jugadores más influyentes. La intención de aplicar esta técnica esta basada en que puede ser útil para resolver el problema de los coeficientes extremos que presentan los jugadores que juegan pocos minutos. Además esto permite una interpretación más significativa del intercepto del modelo implementado, ya que ahora representa la contribución promedio de un jugador de referencia³ en cada posesión.

La penalización en este caso se basa en la suma de los valores absolutos de los coeficientes.

Para el **modelo de regresión lineal múltiple** resulta:

$$S^* = \sum_{i=1}^n w_i (y_i - \mu_i)^2 + \lambda \sum_{j=1}^p |\beta_j| = S + \lambda \sum_{j=1}^p |\beta_j|$$

Para el **modelo logístico multinomial** resulta:

$$L_m^*(\boldsymbol{\beta}, \mathbf{y}) = \sum_{i=1}^n w_i \sum_{j=1}^c y_{ij} \log(\pi_{ij}) + \lambda \sum_{j=1}^p |\beta_j| = L_m(\boldsymbol{\beta}, \mathbf{y}) + \lambda \sum_{j=1}^p |\beta_j|$$

En este caso valores grandes de λ incrementan la penalización, llevando a que un mayor número de coeficientes se reduzcan exactamente a cero.

³Por jugador de referencia entendemos a cualquier jugador que pertenece al grupo de jugadores con coeficientes iguales a cero.

6.6.3 Elastic Net

Cuando existen predictores altamente correlacionados, **ridge** reduce la influencia de todos ellos a la vez de forma proporcional, mientras que **lasso** tiende a seleccionar uno de ellos, dándole todo el peso y excluyendo al resto. En presencia de correlaciones fuertes esta selección puede variar mucho ante pequeñas perturbaciones, por lo que las soluciones de lasso pueden ser más inestables.

Para encontrar un equilibrio entre ambos métodos se plantea la penalización **elastic net**, introducido por Hui Zou y Trevor Hastie (2005), la cual combina las penalizaciones L1 (Lasso) y L2 (Ridge).

Para el **modelo de regresión lineal múltiple** resulta:

$$S^* = \sum_{i=1}^n w_i (y_i - \mu_i)^2 + \lambda \left[\alpha \sum_{j=1}^p |\beta_j| + \frac{(1-\alpha)}{2} \sum_{j=1}^p \beta_j^2 \right] = S + \lambda \sum_{j=1}^p \left[\alpha \sum_{j=1}^p |\beta_j| + \frac{(1-\alpha)}{2} \sum_{j=1}^p \beta_j^2 \right]$$

Para el **modelo logístico multinomial** resulta:

$$L_m^*(\beta, \mathbf{y}) = \sum_{i=1}^n w_i \sum_{j=1}^c y_{ij} \log(\pi_{ij}) + \lambda \sum_{j=1}^p \left[\alpha \sum_{j=1}^p |\beta_j| + \frac{(1-\alpha)}{2} \sum_{j=1}^p \beta_j^2 \right] = L_m(\beta, \mathbf{y}) + \lambda \sum_{j=1}^p \left[\alpha \sum_{j=1}^p |\beta_j| + \frac{(1-\alpha)}{2} \sum_{j=1}^p \beta_j^2 \right]$$

Donde, $\lambda \geq 0$ sigue siendo el parámetro de regularización que controla la fuerza de la penalización, y se agrega un nuevo hiperparámetro $\alpha \in [0, 1]$ que controla la combinación entre lasso y ridge. Si $\alpha = 1$ se obtiene lasso y si $\alpha = 0$ se obtiene ridge.

6.7 Tuneo de hiperparámetros

...

6.8 Comparación de modelos

Una vez que se obtengan los ratings de jugadores a través de las distintas técnicas mencionadas, resulta sumamente importante definir un método para evaluarlos, y de esta manera poder identificar cual es el que ofrece mejores resultados.

En el ámbito del fútbol el profesor Lars Magnus Hvattum plantea una solución muy interesante para esta problemática, la cual no parece haber sido implementada en básquetbol hasta la fecha. En el artículo *Modelling the financial contribution of soccer players to their clubs* (Sæbø & Hvattum, 2019) y en videos de su página de youtube Football Player Ratings se definen 2 criterios diferentes para medir los distintos sistemas de rankings, buscando evaluar la **consistencia** y la **validez** de los mismos.

6.8.1 Bondad de ajuste

...

6.8.2 Evaluación de la consistencia de los resultados

Según Hvattum, un buen modelo producirá resultados similares independientemente de que partidos hayan sido incluidos en el dataset. Bajo este enfoque, si un mismo sistema de rankings brinda estimaciones de RAPMs similares al ser aplicado a distintas muestras del dataset (de tamaños similares), entonces dicho modelo será consistente.

Para evaluar esto, se divide el conjunto de datos completo en dos particiones con cantidades similares de posesiones. Luego, se calculan los valores de RAPM para cada partición y se estima la correlación de Pearson entre ambos conjuntos de coeficientes. Cuanto mayor sea este coeficiente, mayor será la consistencia del modelo.

6.8.3 Criterios de validación externa

...

Procedure for measuring the repeatability of ratings (reliability)




Figura 8: Procedimiento para evaluar la consistencia de los modelos RAPM.
Fuente: Hvattum (2023), *How to evaluate football player ratings?* [Video]. YouTube.

7 Resultados

8 Conclusión

9 Discusión

Los modelos RAPM utilizados en este trabajo, al igual que la literatura previa (Rosenbaum, 2004; Sill, 2010; Damoulaki et al., 2025), consideran cada posesión como una observación independiente. Sin embargo, esta hipótesis puede resultar discutible, dado que las posesiones pertenecientes a un mismo partido presentan dependencia temporal derivada de factores como el ritmo de juego, los ajustes tácticos, la fatiga y el contexto competitivo. Aunque esta dependencia no necesariamente sesga las estimaciones de los coeficientes bajo la hipótesis de exogeneidad de los errores, sí podría afectar su eficiencia y la correcta cuantificación de la incertidumbre. El desarrollo de modelos RAPM que incorporen explícitamente la correlación intra-partido constituye una línea de investigación aún poco explorada.

INTERPRETACIÓN Y COMPARACIÓN DE MODELOS DE REGRESIÓN LOGÍSTICA PARA EL ESTUDIO DE LA DESOCUPACIÓN (regresión logística con correlación, aplicación de modelos gee)

comparar lo escrito en este rmd con el que escribi para el anteproyecto, quizas este era una versión anterior y le faltan correcciones

evaluación de modelos de regresión lineal múltiple

10 Bibliografía

- Agresti, A. (2013). *Categorical Data Analysis* (3rd ed.). Wiley Series in Probability and Statistics. Wiley, New York.
- Damoulaki, A., Ntzoufras, I. & Pelechrinis, K. (2025). *Lasso multinomial performance indicators for in-play basketball data*. Comput Stat 40, 2157–2181.
- Dunn, P. K., & Smyth, G. K. (2018). *Generalized linear models with examples in R*. Springer.
- Hvattum, L. M. (2019). *A comprehensive review of plus-minus ratings for evaluating individual players in team sports*. International Journal of Computer Science in Sport, 18, 1–23.
- Ilardi, S. (2007). *Adjusted Plus-Minus: An idea whose time has come*. Blog: 82games. <http://www.82games.com/ilardi1.htm>
- Ilardi, S., & Barzilai, A. (2008). *Adjusted Plus-Minus ratings: New and improved for 2007–2008*. Blog: 82games. <http://www.82games.com/ilardi2.htm>
- James, G., Witten, D., Hastie, T., & Tibshirani, R. (2021). *An Introduction to Statistical Learning with Applications in R* (ISLR2).
- Kubatko, J., Oliver, D., Pelton, K., & Rosenbaum, D. (2007). *A starting point for analyzing basketball statistics*. Journal of Quantitative Analysis in Sports, 3, Article 1.
- Rosenbaum, D. (2004). *Measuring how NBA players help their teams win*. Blog: 82games. <http://www.82games.com/comm30.htm>
- Sæbø, O., & Hvattum, L. (2019). *Modelling the financial contribution of soccer players to their clubs*. Journal of Sports Analytics, 5, 23–34.
- Sill, J. (2010). *Improved NBA adjusted +/- using regularization and out-of-sample testing*. Proceedings of the 2010 MIT Sloan Sports Analytics Conference.
- Tibshirani, R. (1996). *Regression shrinkage and selection via the lasso*. Journal of the Royal Statistical Society: Series B (Methodological), 58(1), 267–288.

Zou, H., & Hastie, T. (2005). *Regularization and Variable Selection via the Elastic Net*. Journal of the Royal Statistical Society: Series B, 67(2), 301–320.